

데이터 처리와 데이터 시각화

Data Processing and Visualization with MATLAB

Jin Hee Yoon

Dept. of Intelligent Information Convergence

Sejong University

Spring, 2026

- MATLAB을 이용한 데이터 수집 및 정제 능력을 배양한다.
- 외부 데이터(UCI, Kaggle)를 MATLAB 환경으로 로드한다.
- 불완전한 데이터를 처리하는 전처리 기법을 익힌다.
- 분석 결과를 학술적 가치가 있는 고해상도 그래픽으로 표현한다.

1. 데이터 불러오기 및 저장
2. 데이터 구조와 Table 조작
3. 데이터 전처리 (Preprocessing)
4. 기술통계 및 분석
5. 고급 시각화 및 모델링
6. 실습

Part 1

데이터 불러오기 및 저장

Data Import & Export

load 함수를 이용한 수치 데이터 로드

- load 함수는 숫자로만 구성된 .txt 또는 .mat 파일에 적합하다.

data.txt 예시

```
1.0  25.1  45.2
1.5  25.3  45.1
2.0  25.2  46.0
```

```
A = load('data.txt');
time = A(:, 1); % 1열 추출
temp = A(:, 2); % 2열 추출
```

예제: data.txt 파일 생성 (MATLAB)

- 목표: load 함수 실습을 위한 데이터 파일 생성

```
% Step 1: 데이터 생성
```

```
data = [ ...
```

```
    1.0  25.1  45.2;
```

```
    1.5  25.3  45.1;
```

```
    2.0  25.2  46.0
```

```
];
```

```
% Step 2: txt 파일로 저장
```

```
writematrix(data, 'data.txt', 'Delimiter', ' ');
```

```
% 확인
```

```
type data.txt
```

- 파일 내에 숫자가 아닌 문자열이 포함되면 오류가 발생한다.
- 행렬 형태가 직사각형이 아닐 경우(Missing values) 로드할 수 없다.
- %로 시작하는 주석은 무시된다.

예제: students.csv 생성 (MATLAB)

- 목표: readtable 실습용 CSV 파일 생성

```
% Step 1: 데이터 생성
Name = {'Kim'; 'Lee'; 'Park'; 'Choi'; 'Jung'};
Math = [90; 85; 78; 92; 88];
English = [85; 90; 80; 88; 84];
Science = [88; 87; 82; 91; 86];

T = table(Name, Math, English, Science);

% Step 2: CSV 파일로 저장
writetable(T, 'students.csv');

% 확인
type students.csv
```


readtable을 이용한 혼합 데이터 로드

- 텍스트와 숫자가 섞인 CSV나 Excel 파일에 권장된다.

```
T = readtable('students.csv');  
disp(T(1:5, :)); % 상위 5행 출력
```

- 첫 번째 행이 변수 이름(Header)으로 자동 지정된다.

```
% 헤더가 없는 경우  
T = readtable('data.csv', 'ReadVariableNames', false);  
  
% 특정 시트 (sheet 2)만 로드 (Excel)  
T = readtable('data.xlsx', 'Sheet', 2);
```

- 'FileType' 옵션을 통해 파일 형식을 강제 지정할 수 있다.

- **UCI Machine Learning Repository**: 학술용 표준 데이터셋 제공처. <https://archive.ics.uci.edu/>
- 머신러닝 및 데이터 과학 입문에 필수적인 데이터 집합.
- 예시: Iris, Wine, Adult, Housing.

실습: UCI Iris 데이터 직접 로드

- URL을 통해 인터넷에서 데이터를 직접 불러온다.

```
url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/iris/iris.data';  
T = readtable(url, 'FileType', 'text');  
% 변수 이름 수동 지정  
T.Properties.VariableNames = {'SL', 'SW', 'PL', 'PW', 'Species'};  
head(T)
```

- **Kaggle**: 세계 최대의 데이터 과학 커뮤니티 및 경진대회 플랫폼. <https://www.kaggle.com/>
- 실무적이고 대규모인 데이터셋(Titanic, Netflix, COVID-19) 보유.
- 사용 절차: 다운로드 → 현재 폴더 복사 → `readtable`.

실습: Kaggle Titanic 데이터 불러오기

```
T = readtable('titanic_train.csv');  
% 기본 정보 요약  
summary(T)
```

- `summary` 함수를 통해 각 열의 데이터 타입과 기초 통계를 확인한다.

공개 데이터 사이트 (해외)

- Google Dataset Search <https://datasetsearch.research.google.com/>
- World Bank Open Data <https://data.worldbank.org/>
- data.gov (미국 정부 데이터) <https://www.data.gov/>
- EU Open Data Portal <https://data.europa.eu/>
- OpenML <https://www.openml.org/>
- Papers With Code (Datasets) <https://paperswithcode.com/datasets>
- AWS Open Data Registry <https://registry.opendata.aws/>
- Yahoo Finance <https://finance.yahoo.com/>
- NOAA Climate Data <https://www.noaa.gov/>
- ImageNet <https://www.image-net.org/>
- PhysioNet <https://physionet.org/>

공개 데이터 사이트 (국내)

- 공공데이터포털 <https://www.data.go.kr/>
- KOSIS (국가통계포털) <https://kosis.kr/>
- 한국은행 경제통계시스템 <https://ecos.bok.or.kr/>
- AI Hub <https://aihub.or.kr/>
- 서울 열린데이터광장 <https://data.seoul.go.kr/>
- 국가공간정보포털 <https://www.nsdi.go.kr/>

분석 결과 저장하기

- MATLAB 변수를 외부 파일로 내보낸다.

```
clc;  
writetable(T, 'processed_data.csv');  
writetable(T, 'results.xlsx', 'Sheet', 'Final');
```

%% Table 출력

%CSV → type, readtable 둘 다 가
능
xlsx 는 readtable 만 가능

```
type processed_data.csv  
readtable ('processed_data.csv')  
readtable('results.xlsx', 'Sheet', 'Final')
```

MATLAB 전용 형식 (.mat)

- save 함수를 통해 작업 공간(Workspace)의 변수를 그대로 저장한다.

```
save('my_project.mat', 'T', 'time', 'temp');
```

% 다시 불러오기

```
load('my_project.mat');
```

온라인 데이터 다운로드: webservice

- webservice 함수는 인터넷에 있는 파일을 로컬 컴퓨터로 다운로드한다.
- 이후 readtable, readmatrix 등으로 분석 가능하다.

```
filename = webservice('저장파일명', 'URL');
```

- 반환값: 다운로드된 파일의 이름
- 주로 CSV, TXT, 데이터셋 다운로드에 사용

websave + readtable 사용 예

- **목표:** 온라인 Wine 데이터를 다운로드 후 분석

```
url = ['https://archive.ics.uci.edu/ml/machine-learning-databases/' ...  
      'wine/wine.data'];  
  
% Step 1: 다운로드  
file = websave('wine_data.csv', url);  
  
% Step 2: 불러오기  
T = readtable(file, 'FileType','text', 'ReadVariableNames', false);  
  
% Step 3: 일부 데이터 확인  
head(T)
```

- **핵심 흐름:**

websave → readtable → 분석

데이터 로드 방법 비교 요약

함수	주 용도	비고
load	순수 수치 행렬	가장 빠름
readtable	혼합 데이터 (CSV)	가장 범용적
xlsread	구버전 Excel	현재는 지양
websave	온라인 파일 다운로드	자동화 가능

[실습 1] 자신만의 데이터 로드 루틴 만들기

- **목표:** 텍스트 파일을 직접 만들고 로드해본다.

```
% Step 1: 메모장에 아래 내용 입력 후 'test.txt' 저장
1, 10
2, 20
3, 30

% Step 2: MATLAB에서 로드
data = readmatrix('test.txt');
plot(data(:,1), data(:,2), '-o');
```

Part 2

데이터 구조와 Table 조작

Data Structures & Table Manipulation

Table 자료형의 장점

- 서로 다른 타입의 데이터(숫자, 문자열, 날짜)를 한 변수에 담을 수 있다.
- 각 열에 고유한 이름을 부여하여 가독성을 높인다.
- 엑셀의 데이터 시트와 유사한 구조로 설계되었다.

Table 변수(열) 접근 방식

- 점 연산자(.)를 사용하여 특정 열의 데이터를 벡터로 추출한다.

```
% 'Age' 열 데이터 전체 추출
```

```
age_vector = T.Age;
```

```
% 'Name' 열 데이터 전체 추출
```

```
name_list = T.Name;
```

Table에 변수 추가하기 (1)

```
%% 데이터 Matrix 생성 후 Table 변환한 후 변수추가하기
%% Step 1: 데이터 불러오기 또는 Matlab 내부에서 생성하기
(scores.dat 파일 생성)
clc;
scores = [ ...
    85  90  88;
    78  82  80;
    92  91  95;
    70  75  72;
    88  85  84
];

writematrix(scores, 'scores.dat', 'Delimiter', ' ');

%% Step 2: 파일 로드

A = load('scores.dat');
```

Table 변환 및 총점/평균 계산

```
% Step 3: Table로 변환
T_score = array2table(A, ...
    'VariableNames', {'Math', 'English', 'Science'});

% Step 4: 총점 및 평균 계산
T_score.Total = T_score.Math + T_score.English + T_score.Science;
T_score.Average = T_score.Total / 3;

% 결과 확인
disp(T_score)
```

Table에 변수 추가하기 (2)

- 데이터를 불러와서 사용할 수도 있지만 데이터를 생성해서 분석시에는 데이터 생성시 **matrix보다 table을 직접 생성하는 것이 권장된다.**
- 변수 이름을 명시적으로 부여할 수 있어 해석이 직관적이다.

```
% Table 직접 생성 후 변수추가하기
clc;
Math = [85;78;92;70;88];
English = [90;82;91;75;85];
Science = [88;80;95;72;84];

T_score1 = table(Math, English, Science);
T_score1.Total = T_score1.Math + T_score1.English + T_score1.Science;
T_score1.Average = T_score1.Total / 3;

disp(T_score1)
```

숫자와 문자열이 혼합된 Table 생성

- 다양한 자료형(숫자, 문자열, 논리값)을 하나의 table로 구성

%% 데이터 생성

```
ID      = [1; 2; 3; 4];  
Name     = ["Alice"; "Bob"; "Charlie"; "David"];  
Age      = [20; 25; 23; 22];  
Gender   = ["F"; "M"; "M"; "M"];  
Score    = [88.5; 92.0; 79.5; 85.0];  
Passed   = [true; true; false; true];
```

% table 생성

```
T_score2 = table(ID, Name, Age, Gender, Score, Passed)  
disp(T_score2)
```

참고) ' ' → char (문자 배열)

" " → string (문자열 객체, string array)

점수 데이터에서 조건 추출

- T_score에서 평균 점수가 90점 이상인 학생을 추출한다.

```
%% 평균 점수 90 이상 학생 추출
```

```
high_score = T_score(T_score.Average >= 90, :);
```

```
%% 결과 확인
```

```
disp(high_score)
```

Titanic 데이터에서 성별 추출

- T에서 성별이 여성(female)인 승객만 추출한다.

%% 여성 승객 추출, string compare (문자열 비교)의미

```
females = T(strcmp(T.Sex, 'female'), :);
```

%% 결과 확인

```
disp(females)
```

점 표기법을 이용한 변수 추출

설명: 변수명(column name)을 이용하여 특정 열 추출

```
% Name 변수 추출
```

```
T_score2.Name
```

```
% Score 변수 추출
```

```
T_score2.Score
```

```
% Passed 변수 추출
```

```
T_score2.Passed
```


중괄호를 이용한 데이터 추출

설명: 사용 → 실제 데이터 배열 반환

```
% Score 열의 실제 데이터
scoreData = T_score2(:, 'Score')

% Age와 Score 두 열의 실제 데이터
numericData = T_score2(:, {'Age', 'Score'})

% 일부 행 데이터
partialScore = T_score2(1:3, 'Score')
```

주의: table이 아닌 숫자 배열 반환

소괄호를 이용한 Table 부분 추출

설명: () 사용 → 결과가 table 형식 유지

```
% Score 열만 table로 추출
scoreTable = T_score2(:, 'Score')

% 여러 열 선택
selectedTable = T_score2(:, {'Name', 'Score', 'Passed'})

% 일부 행 + 일부 열
smallTable = T_score2(1:2, {'Name', 'Score'})
```

조건을 이용한 데이터 추출

설명: 조건식을 이용하여 행과 변수 선택

```
% 점수 85 이상
T_score2(T_score2.Score >= 85, :)

% 점수 85 이상 + 일부 변수
T_score2(T_score2.Score >= 85, {'Name', 'Score'})

% 통과한 학생 이름 (데이터 형태)
passedNames = T_score2{T_score2.Passed == true, 'Name'}

% 남학생의 Age, Score
maleData = T_score2(T_score2.Gender == "M", {'Age', 'Score'})
```

Cell 배열 (Cell Array)

- Table 은 주로 데이터를 분석하기 위해 사용하고 셀배열, 구조체배열은 데이터를 저장하기 위해 사용한다.
- 크기와 타입이 서로 다른 데이터를 저장하는 배열이다.
- 중괄호(\{\})를 사용하여 생성 및 색인한다.
- 예: 문장의 각 단어 저장, 다양한 크기의 행렬 저장.

```
C = {'Sejong', [1 2; 3 4], 3.14};
```

% 내용물 접근 (중괄호 사용)

```
val1 = C{1}; % 'Sejong'
```

```
val2 = C{2}; % 2x2 matrix
```

% 셀 자체 접근 (소괄호 사용)

```
sub_cell = C(1:2);
```

구조체 (Structure)

- 필드명(Field name)을 사용하여 데이터를 분류 저장한다.
- 연구 데이터 관리 시 매우 유용하다.
- 예: `student.name`, `student.id`, `student.gpa`.

```
S.name = 'Yoon';  
S.dept = 'AI';  
S.score = [90 85 95];  
  
% 필드 접근  
avg_score = mean(S.score);
```

- 행렬 연산이 필요한 경우 Table을 Matrix로 변환해야 한다.

```
% Table -> Array
```

```
A = table2array(T(:, 2:5));
```

```
% Array -> Table
```

```
T_new = array2table(A, 'VariableNames', {'V1', 'V2', 'V3', 'V4'});
```


- 특정 열의 값을 기준으로 전체 데이터를 정렬한다.

% 수학 점수 기준 내림차순 정렬

```
T_sorted = sortrows(T_score, 'Math', 'descend');
```

% 이름 기준 오름차순 정렬

```
T_sorted2 = sortrows(T_score, 'Name', 'ascend');
```

[실습 2] 데이터 필터링 및 정렬

- **목표:** Iris 데이터에서 'Setosa' 품종만 추출하여 꽃잎 길이순으로 정렬한다.

```
setosa = T(strcmp(T.Species, 'Iris-setosa'), :);  
result = sortrows(setosa, 'PL', 'ascend');  
disp(head(result));
```

Part 3

데이터 전처리 (Preprocessing)

Data Cleaning & Transformation

전처리(Preprocessing)의 목적

- **"Garbage In, Garbage Out"**: 데이터가 지저분하면 분석 결과도 믿을 수 없다.
- **목적:**
 - 결측치(NaN) 제거 및 대체
 - 이상치(Outlier) 탐지 및 정정
 - 데이터 정규화(Normalization)

결측치 (Missing Values / NaN)

- **NaN (Not-a-Number)**: 측정이 되지 않았거나 정의되지 않은 수치 데이터.
- MATLAB에서 수치 연산 중 NaN이 포함되면 결과도 NaN이 된다.
- 예: `mean([1, 2, NaN])` → NaN

- `isnan` 함수를 사용하여 NaN의 위치를 논리 배열로 반환한다.

```
x = [1, NaN, 3, 4, NaN];  
idx = isnan(x); % [0 1 0 0 1]
```

```
% 결측치의 개수 확인  
num_nan = sum(idx);
```

결측치 제거 루틴

- `rmmissing` 함수를 사용하여 NaN이 포함된 행을 한 번에 삭제한다.

```
T_clean = rmmissing(T);
```

- 데이터의 양이 충분히 많을 때 권장되는 방법이다.

결측치 대체 (Imputation)

- 데이터를 삭제하지 않고 합리적인 값으로 채워 넣는다.

% 0으로 채우기

```
T_fixed = fillmissing(T, 'constant', 0);
```

% 이전 값으로 채우기

```
T_fixed = fillmissing(T, 'previous');
```

% 선형 보간법으로 채우기

```
T_fixed = fillmissing(T, 'linear');
```


이상치 (Outlier) 탐지

- 정의: 다른 관측치와 현저하게 다른 비정상적인 값.
- 판단 기준:
 - 통계적 기준: 3σ (표준편차) 이상 떨어진 값.
 - 사분위수 기준: IQR의 1.5배 이상 벗어난 값.

이상치 제거 루틴 (논리 연산)

- 논리 연산자를 결합하여 이상치를 필터링한다.

```
mu = mean(data); sig = std(data);  
% 평균에서 3표준편차 이내인 데이터만 유지  
clean_data = data(abs(data - mu) <= 3*sig);
```

루프를 이용한 이상치 탐지 (1/2)

- 이전 챕터의 for 문을 활용한 데이터 순회.

```
[R, C] = size(data);  
for i = 1:R  
    if data(i) > 1000 % 특정 기준 초과 시  
        data(i) = NaN; % 이상치를 NaN으로 처리  
    end  
end
```

루프를 이용한 이상치 탐지 (2/2)

- 다차원 배열에서 각 원소를 검사할 때 중첩 루프를 사용한다.

```
for i = 1:size(A, 1)
    for j = 1:size(A, 2)
        if A(i,j) < 0
            A(i,j) = 0; % 음수 데이터 정정
        end
    end
end
```

데이터 정규화 (Min-Max Scaling)

- 서로 다른 단위의 데이터를 0 ~ 1 사이로 변환한다.

```
mn = min(data);  
mx = max(data);  
norm_data = (data - mn) ./ (mx - mn);
```

- 연산 시 ./와 .- 등 원소 단위 연산자 사용에 주의한다.

데이터 표준화 (Standardization)

- 평균을 0, 표준편차를 1로 맞춘다.

```
mu = mean(data);  
sig = std(data);  
std_data = (data - mu) ./ sig;  
  
% MATLAB 내장 함수 활용  
std_data = zscore(data);
```

[실습 3] 종합 데이터 정제

- **목표:** Titanic 데이터에서 Age의 결측치를 평균으로 채우고, 운임(Fare)의 이상치를 제거한다.

```
T.Age = fillmissing(T.Age, 'constant', mean(T.Age, 'omitnan'));  
mu_f = mean(T.Fare); sig_f = std(T.Fare);  
T_final = T(T.Fare <= mu_f + 3*sig_f, :);
```

Part 4

기술통계 및 탐색적 분석

Descriptive Statistics & EDA

- mean: 평균
- median: 중앙값
- std: 표준편차
- var: 분산
- min / max: 최솟값 / 최댓값
- mode: 최빈값

그룹별 통계 계산 (groupsummary)

- 카테고리별로 통계 지표를 한 번에 계산한다.

```
% 등급(Grade)별 수학 점수의 평균과 표준편차  
stats = groupsummary(T, 'Grade', {'mean', 'std'}, 'Math');  
disp(stats);
```

상관관계 분석 (corrcoef)

- 두 변수 사이의 선형적 관계 강도를 측정한다.

```
R = corrcoef(T.Math, T.Science);  
fprintf('상관계수: %.2f\n', R(1, 2));
```

- 1에 가까울수록 양의 상관관계, -1에 가까울수록 음의 상관관계.

- 모든 변수 쌍의 산점도를 한꺼번에 그린다.

```
data_vars = table2array(T(:, 2:5));  
plotmatrix(data_vars);
```

- 논리 변수를 인덱스로 사용하여 특정 집단의 평균 구하기.

```
is_setosa = strcmp(T.Species, 'Iris-setosa');  
avg_sl = mean(T.SL(is_setosa));
```

[실습 4] 데이터 요약 실습

- **목표:** Titanic 데이터에서 생존 여부(Survived)별 평균 나이를 계산한다.

```
T_clean = rmmissing(T, 'DataVariables', 'Age');  
G = groupsummary(T_clean, 'Survived', 'mean', 'Age');  
disp(G);
```

Part 5

고급 시각화 및 모델링

Advanced Graphics & Data Modeling

- LaTeX 인터프리터를 사용하여 수식을 미려하게 표현한다.

```
plot(time, temp, 'LineWidth', 2, 'Color', 'r');  
xlabel('Time ($s$)', 'Interpreter', 'latex');  
ylabel('Temp ($^{\circ}\text{C}$)', 'Interpreter', 'latex');  
title('Temperature Variation $\sin(\omega t)$');
```


- 축 설정 및 폰트 크기 최적화.

```
set(gca, 'FontSize', 12, 'FontName', 'Times New Roman');  
grid on;  
set(gca, 'LineWidth', 1.2);
```

다중 패널 구성 (tiledlayout)

- subplot보다 유연한 배치가 가능하다.

```
t = tiledlayout(2, 1);  
nexttile; plot(v1); title('Data 1');  
nexttile; plot(v2); title('Data 2');  
title(t, 'Integrated Dashboard');
```

3차원 곡면 그래프 (surf)

- 다변수 함수의 변화를 입체적으로 관찰한다.

```
[X, Y] = meshgrid(-2:0.1:2, -2:0.1:2);  
Z = X .* exp(-X.^2 - Y.^2);  
surf(X, Y, Z);  
colorbar; shading interp;
```

- 관측된 데이터의 추세를 수식으로 도출한다.

```
p = polyfit(x, y, 2); % 2차식 피팅
y_fit = polyval(p, x_new);

plot(x, y, 'o', x_new, y_fit, '-');
```

- 논문에 삽입할 수 있는 고해상도 PDF/PNG 파일 생성.

```
exportgraphics(gcf, 'result.pdf', 'ContentType', 'vector');  
exportgraphics(gcf, 'result.png', 'Resolution', 300);
```

Part 6

종합 실습문제

Final Practice

실습문제 1: txt 파일 생성과 시각화

MATLAB 안에서 직접 수치 데이터를 생성한 뒤, 이를 `data.txt` 파일로 저장하고 다시 불러와 그래프로 나타내시오.

- (1) $x = 1, 2, \dots, 50$ 인 열벡터를 만들고, $y = 2x + \epsilon$ 형태의 데이터를 생성하시오. 여기서 ϵ 은 `randn`을 이용한 잡음으로 생성하시오.
- (2) x 와 y 를 하나의 행렬로 묶어 `data.txt` 파일로 저장하시오.
- (3) `data.txt` 파일을 다시 불러와 x - y 선 그래프를 그리시오.

실습문제 2: students.csv 생성과 로드

MATLAB 안에서 학생 20명의 성적 데이터를 직접 생성한 뒤, CSV 파일로 저장하고 다시 불러오시오.

- (1) 학생 이름은 Student1, Student2, ..., Student20 형식으로 생성하시오.
- (2) Math, English, Science 점수는 각각 60점 이상 100점 이하의 정수 난수로 생성하시오.
- (3) 생성한 table을 students.csv로 저장한 뒤 다시 불러와 처음 5행을 출력하시오.

실습문제 3: Table 열 접근과 평균 계산

students.csv에서 불러온 학생 성적 table T를 이용하여 각 과목의 평균 점수를 계산하시오.

- (1) T.Math, T.English, T.Science를 이용하여 각 과목 점수 열에 접근하시오.
- (2) 각 과목의 평균 점수를 각각 계산하시오.
- (3) 계산된 평균 점수를 하나의 table로 정리하여 출력하시오.

실습문제 4: Table에 총점과 평균 열 추가

학생 성적 table T에 총점과 평균 점수를 새로운 열로 추가하시오.

- (1) Math, English, Science를 더하여 Total 열을 추가하시오.
- (2) 세 과목 평균을 계산하여 Average 열을 추가하시오.
- (3) 수정된 table의 처음 5행을 출력하시오.

실습문제 5: 조건 필터링과 정렬

학생 성적 table T에서 조건을 만족하는 학생만 추출하고 평균 점수 기준으로 정렬하시오.

- (1) 수학 점수가 90점 이상인 학생을 추출하시오.
- (2) 평균 점수가 85점 이상인 학생을 추출하시오.
- (3) 두 조건을 동시에 만족하는 학생을 추출한 뒤, 평균 점수 기준 내림차순으로 정렬하시오.

실습문제 6: 처리된 성적 데이터 저장과 재로드

총점과 평균이 추가된 학생 성적 데이터를 새로운 CSV 파일로 저장하고 다시 불러오시오.

- (1) 현재 table T를 `processed_students.csv` 파일로 저장하시오.
- (2) 저장된 파일을 다시 `readtable`로 불러오시오.
- (3) 다시 불러온 table의 변수 이름과 처음 5행을 확인하시오.

실습문제 7: websave를 이용한 Wine 데이터 다운로드

UCI Wine 데이터를 MATLAB 안에서 다운로드한 뒤 table로 불러오시오.

- (1) UCI Wine 데이터 URL을 변수 `url`에 저장하시오.
- (2) `websave`를 이용하여 데이터를 `wine.csv` 파일로 저장하시오.
- (3) 저장된 `wine.csv` 파일을 `readtable`로 불러오고 변수 이름을 지정하시오.

실습문제 8: 결측치 생성과 평균 대체

학생 성적 데이터에 의도적으로 결측치를 만든 뒤, 각 과목 평균으로 대체하시오.

- (1) Math의 3번째 값, English의 7번째 값, Science의 12번째 값을 NaN으로 바꾸시오.
- (2) 각 과목의 결측치 개수를 계산하시오.
- (3) 각 과목의 결측치를 해당 과목 평균으로 대체하시오.

실습문제 9: 센서 데이터 생성과 이상치 처리

시간에 따라 변화하는 온도 센서 데이터를 생성하고, 일부 이상치를 찾아 제거하시오.

- (1) 시간 $t = 1, 2, \dots, 100$ 에 대해 온도 데이터 `temp`를 생성하시오.
- (2) 20번째, 50번째, 80번째 위치에 비정상적으로 큰 값을 넣어 이상치를 만드시오.
- (3) 평균에서 3표준편차를 초과하여 벗어난 값을 NaN으로 바꾸고 그래프로 비교하시오.

실습문제 10: 정규화와 표준화 비교

학생들의 평균 점수 `Average`를 이용하여 정규화와 표준화를 비교하시오.

- (1) `Average`를 0과 1 사이로 Min-Max 정규화하시오.
- (2) `Average`를 평균 0, 표준편차 1이 되도록 Z-score 표준화하시오.
- (3) 원래 평균 점수, 정규화 값, 표준화 값을 하나의 table로 정리하시오.

실습문제 11: 그룹별 성적 통계 분석

학생 20명을 두 개의 반으로 나누고, 반별 평균 점수를 비교하시오.

- (1) 앞의 10명은 ClassA, 뒤의 10명은 ClassB로 표시하는 Class 열을 추가하시오.
- (2) Class별 Average의 평균과 표준편차를 계산하시오.
- (3) Class별 평균 점수 분포를 boxplot으로 나타내시오.

실습문제 12: Wine 데이터 상관관계와 산점도

다운로드한 Wine 데이터를 이용하여 변수 간 관계를 분석하시오.

- (1) Alcohol, MalicAcid, Ash, ColorIntensity 네 변수를 선택하시오.
- (2) 선택한 네 변수의 상관계수 행렬을 계산하시오.
- (3) 선택한 네 변수에 대해 산점도 행렬을 그리시오.

실습문제 13: 다항식 피팅과 결과 저장

잡음이 포함된 2차 함수 데이터를 생성하고, 다항식 피팅 결과를 그래프로 저장하시오.

- (1) $x = -5$ 부터 5까지 30개의 점을 만들고, $y = 2x^2 - 3x + 5 + \epsilon$ 형태의 데이터를 생성하시오.
- (2) `polyfit`을 이용하여 2차 다항식을 적합하고 예측값을 계산하시오.
- (3) 원자료와 피팅 곡선을 함께 그리고 `polyfit_result.png` 파일로 저장하시오.

실습문제 14: UCI Auto MPG 데이터 분석

UCI Auto MPG 데이터를 다운로드하여 자동차 연비와 주요 변수의 관계를 분석하시오.

- (1) websave를 이용하여 UCI Auto MPG 데이터를 다운로드하시오.
- (2) mpg, horsepower, weight, acceleration 변수를 포함하는 table을 만드시오.
- (3) 결측값을 제거한 뒤, weight와 mpg의 산점도를 그리고 상관계수를 계산하시오.

실습문제 15: UCI Breast Cancer Wisconsin 데이터 분석

UCI Breast Cancer Wisconsin Diagnostic 데이터를 다운로드하여 진단 그룹별 특성을 비교하시오.

- (1) WDBC 데이터를 다운로드하고 table로 불러오시오.
- (2) Diagnosis가 M인 경우와 B인 경우를 구분하시오.
- (3) 진단 그룹별 RadiusMean, TextureMean, AreaMean의 평균을 계산하시오.

실습문제 16: Kaggle Titanic 데이터 분석

Kaggle Titanic train.csv 파일을 다운로드하여 생존 여부에 따른 승객 특성을 분석하시오.

- (1) Kaggle에서 train.csv 파일을 다운로드하여 현재 MATLAB 폴더에 저장하시오.
- (2) readtable로 데이터를 불러오고, Age의 결측치를 평균으로 대체하시오.
- (3) 성별과 객실 등급별 생존율을 계산하고 막대그래프로 나타내시오.

코드 답안 1: txt 파일 생성과 시각화

```
x = (1:50)';  
y = 2*x + randn(50,1);  
  
data = [x y];  
  
writematrix(data, 'data.txt', 'Delimiter', ' ');  
  
A = load('data.txt');  
  
x_loaded = A(:,1);  
y_loaded = A(:,2);  
  
plot(x_loaded, y_loaded, '-o')  
grid on  
xlabel('x')  
ylabel('y')  
title('Data Loaded from data.txt')
```

코드 답안 2: students.csv 생성과 로드

```
Name = strings(20,1);

for i = 1:20
    Name(i) = "Student" + i;
end

Math = randi([60 100], 20, 1);
English = randi([60 100], 20, 1);
Science = randi([60 100], 20, 1);

T = table(Name, Math, English, Science);

writetable(T, 'students.csv');

T = readtable('students.csv');

disp(T(1:5, :))
```


코드 답안 3: Table 열 접근과 평균 계산

```
math_score = T.Math;
english_score = T.English;
science_score = T.Science;

mean_math = mean(math_score);
mean_english = mean(english_score);
mean_science = mean(science_score);

MeanTable = table(mean_math, mean_english, mean_science);

disp(MeanTable)
```

코드 답안 4: Table에 총점과 평균 열 추가

```
T.Total = T.Math + T.English + T.Science;  
  
T.Average = T.Total / 3;  
  
disp(T(1:5, :))
```

코드 답안 5: 조건 필터링과 정렬

```
top_math = T(T.Math >= 90, :);  
  
high_average = T(T.Average >= 85, :);  
  
selected = T(T.Math >= 90 & T.Average >= 85, :);  
  
selected_sorted = sortrows(selected, 'Average', 'descend');  
  
disp(top_math)  
disp(high_average)  
disp(selected_sorted)
```

코드 답안 6: 처리된 성적 데이터 저장과 재로드

```
writetable(T, 'processed_students.csv');  
  
T_processed = readtable('processed_students.csv');  
  
disp(T_processed.Properties.VariableNames)  
  
disp(T_processed(1:5, :))
```

코드 답안 7: websave를 이용한 Wine 데이터 다운로드

```
url = ['https://archive.ics.uci.edu/ml/machine-learning-databases/' ...  
      'wine/wine.data'];  
  
file = websave('wine.csv', url);  
  
Wine = readtable(file, 'FileType', 'text', ...  
                'ReadVariableNames', false);  
  
Wine.Properties.VariableNames = {'Class','Alcohol','MalicAcid', ...  
                                'Ash','Alcalinity','Magnesium','Phenols','Flavanoids', ...  
                                'Nonflavanoid','Proanthocyanins','ColorIntensity', ...  
                                'Hue','OD280','Proline'};  
  
disp(Wine(1:5, :))
```

코드 답안 8: 결측치 생성과 평균 대체

```
T_missing = T;

T_missing.Math(3) = NaN;
T_missing.English(7) = NaN;
T_missing.Science(12) = NaN;

num_math_nan = sum(isnan(T_missing.Math));
num_english_nan = sum(isnan(T_missing.English));
num_science_nan = sum(isnan(T_missing.Science));

fprintf('Math NaN: %d\n', num_math_nan)
fprintf('English NaN: %d\n', num_english_nan)
fprintf('Science NaN: %d\n', num_science_nan)

T_missing.Math = fillmissing(T_missing.Math, ...
    'constant', mean(T_missing.Math, 'omitnan'));

T_missing.English = fillmissing(T_missing.English, ...
    'constant', mean(T_missing.English, 'omitnan'));

T_missing.Science = fillmissing(T_missing.Science, ...
```

코드 답안 9: 센서 데이터 생성과 이상치 처리

```
t = (1:100)';

temp = 25 + 2*sin(t/10) + randn(100,1);

temp([20 50 80]) = [50 55 60];

mu = mean(temp);
sig = std(temp);

idx_outlier = abs(temp - mu) > 3*sig;

temp_clean = temp;
temp_clean(idx_outlier) = NaN;

plot(t, temp, '-o')
hold on
plot(t, temp_clean, '-x')
grid on
xlabel('Time')
ylabel('Temperature')
legend('Original', 'Cleaned')
```

코드 답안 10: 정규화와 표준화 비교

```
avg = T.Average;  
  
avg_minmax = (avg - min(avg)) ./ (max(avg) - min(avg));  
  
avg_zscore = (avg - mean(avg)) ./ std(avg);  
  
Result = table(avg, avg_minmax, avg_zscore, ...  
    'VariableNames', {'Average', 'MinMax', 'Zscore'});  
  
disp(Result)
```


코드 답안 11: 그룹별 성적 통계 분석

```
Class = strings(height(T),1);

Class(1:10) = "ClassA";
Class(11:20) = "ClassB";

T.Class = Class;

G = groupsummary(T, 'Class', {'mean','std'}, 'Average');

disp(G)

boxplot(T.Average, T.Class)
xlabel('Class')
ylabel('Average')
title('Average Score by Class')
grid on
```

코드 답안 12: Wine 데이터 상관관계와 산점도

```
X = table2array(Wine(:, ...  
    {'Alcohol', 'MalicAcid', 'Ash', 'ColorIntensity'}));  
  
R = corrcoef(X);  
  
disp(R)  
  
plotmatrix(X)  
title('Scatter Plot Matrix for Wine Data')
```

코드 답안 13: 다항식 피팅과 결과 저장

```
x = linspace(-5, 5, 30)';

y = 2*x.^2 - 3*x + 5 + 5*randn(size(x));

p = polyfit(x, y, 2);

x_new = linspace(min(x), max(x), 200)';
y_fit = polyval(p, x_new);

plot(x, y, 'o')
hold on
plot(x_new, y_fit, '-', 'LineWidth', 2)
grid on
xlabel('x')
ylabel('y')
legend('Original data', 'Fitted curve', 'Location', 'best')
title('Quadratic Polynomial Fitting')

exportgraphics(gcf, 'polyfit_result.png', 'Resolution', 300);
```

코드 답안 14: UCI Auto MPG 데이터 다운로드

```
%% Step 1: Auto MPG CSV 파일 다운로드

url = ['https://raw.githubusercontent.com/mwaskom/' ...
      'seaborn-data/master/mpg.csv'];

file = websave('auto_mpg.csv', url);

%% Step 2: CSV 파일을 table로 불러오기

Auto = readtable(file);

%% Step 3: 일부 데이터 확인

disp(Auto(1:5, :))
```

코드 답안 14: 필요한 변수 선택 및 CSV 저장

%% Step 4: 필요한 변수만 선택

```
Auto_small = Auto(:, ...  
    {'mpg', 'horsepower', 'weight', 'acceleration'});
```

%% Step 5: 선택한 데이터를 CSV로 저장

```
writetable(Auto_small, 'auto_mpg_selected.csv');
```

%% Step 6: 저장한 CSV를 다시 table로 불러오기

```
Auto_small = readtable('auto_mpg_selected.csv');
```

```
disp(Auto_small(1:5, :))
```

코드 답안 14: 결측값 제거

```
%% Step 7: horsepower 결측값 제거

Auto_clean = Auto_small( ...
    ~isnan(Auto_small.horsepower), :);

disp(Auto_clean(1:5, :))
```

코드 답안 14: 산점도와 상관계수

```
%% Step 8: weight와 mpg의 산점도

plot(Auto_clean.weight, Auto_clean.mpg, 'o')
grid on
xlabel('Weight')
ylabel('MPG')
title('Auto MPG: Weight vs MPG')

%% Step 9: 상관계수 계산

R = corrcoef(Auto_clean.weight, Auto_clean.mpg);

fprintf('Correlation = %.3f\n', R(1,2))
```

코드 답안 15: WDBC 데이터 다운로드 및 로드

```
%% Step 1: WDBC CSV 다운로드

url = ['https://raw.githubusercontent.com/selva86/' ...
      'datasets/master/BreastCancer.csv'];

file = websave('wdbc.csv', url);

%% Step 2: table로 불러오기

WDBC = readtable(file);

disp(WDBC(1:5, :))
```


코드 답안 15: 진단 그룹 구분

```
%% Step 3: Diagnosis가 M / B 구분

M_group = WDBC(strcmp(WDBC.diagnosis, 'M'), :);
B_group = WDBC(strcmp(WDBC.diagnosis, 'B'), :);

disp(M_group(1:5, :))
disp(B_group(1:5, :))
```

코드 답안 15: 그룹별 평균 계산

```
%% Step 4: 필요한 변수 선택
```

```
WDBC_small = WDBC(:, ...  
    {'radius_mean', 'texture_mean', 'area_mean', 'diagnosis'});
```

```
%% Step 5: 그룹별 평균 계산
```

```
G = groupsummary(WDBC_small, 'diagnosis', ...  
    'mean', {'radius_mean', 'texture_mean', 'area_mean'});
```

```
disp(G)
```

코드 답안 16: Titanic 데이터 로드

```
%% Step 1: CSV 파일 불러오기
```

```
T = readtable('train.csv');
```

```
disp(T(1:5, :))
```

코드 답안 16: 결측값 처리

```
%% Step 2: Age 결측값 평균으로 대체

T.Age = fillmissing(T.Age, ...
    'constant', mean(T.Age, 'omitnan'));

disp(T(1:5, :))
```

코드 답안 16: 성별별 생존율

```
% Step 3: 성별별 생존율
```

```
G1 = groupsummary(T, 'Sex', 'mean', 'Survived');
```

```
disp(G1)
```

코드 답안 16: 객실 등급별 생존율 + 그래프

```
%% Step 4: 객실 등급별 생존율

G2 = groupsummary(T, 'Pclass', 'mean', 'Survived');

disp(G2)

%% Step 5: 막대그래프

bar(G2.Pclass, G2.mean_Survived)

grid on
xlabel('Passenger Class')
ylabel('Survival Rate')
title('Titanic Survival Rate by Class')
```