

6-1. 데이터 전처리

Data Preprocessing with MATLAB

Jin Hee Yoon

Dept. of Artificial Intelligence and Information Technology

Sejong University

Spring, 2026

- MATLAB을 이용한 데이터 수집 및 정제 능력을 배양한다.
- 외부 데이터(UCI, Kaggle)를 MATLAB 환경으로 로드한다.
- 불완전한 데이터를 처리하는 전처리 기법을 익힌다.

1. 데이터 불러오기 및 저장
2. 데이터 구조와 Table 조작
3. 데이터 전처리 (Preprocessing)
4. 기술통계 및 분석
5. 고급 시각화 및 모델링
6. 실습

Part 1

데이터 불러오기 및 저장

Data Import & Export

load 함수를 이용한 수치 데이터 로드

- load 함수는 숫자로만 구성된 .txt 또는 .mat 파일에 적합하다.

data.txt 예시

```
1.0  25.1  45.2
1.5  25.3  45.1
2.0  25.2  46.0
```

```
A = load('data.txt');
time = A(:, 1); % 1열 추출
temp = A(:, 2); % 2열 추출
```

예제: data.txt 파일 생성 (MATLAB)

- 목표: load 함수 실습을 위한 데이터 파일 생성

```
% Step 1: 데이터 생성
data = [ ...
        1.0  25.1  45.2;
        1.5  25.3  45.1;
        2.0  25.2  46.0
    ];

% Step 2: txt 파일로 저장
writematrix(data, 'data.txt', 'Delimiter', ' ');

% 확인
type data.txt
```

- 파일 내에 숫자가 아닌 문자열이 포함되면 오류가 발생한다.
- 행렬 형태가 직사각형이 아닐 경우(Missing values) 로드할 수 없다.
- %로 시작하는 주석은 무시된다.

예제: students.csv 생성 (MATLAB)

- 목표: readtable 실습용 CSV 파일 생성

```
% Step 1: 데이터 생성
Name = {'Kim'; 'Lee'; 'Park'; 'Choi'; 'Jung'};
Math = [90; 85; 78; 92; 88];
English = [85; 90; 80; 88; 84];
Science = [88; 87; 82; 91; 86];

T = table(Name, Math, English, Science);

% Step 2: CSV 파일로 저장
writetable(T, 'students.csv');

% 확인
type students.csv
```


readtable을 이용한 혼합 데이터 로드

- 텍스트와 숫자가 섞인 CSV나 Excel 파일에 권장된다.

```
T = readtable('students.csv');  
disp(T(1:5, :)); % 상위 5행 출력
```

- 첫 번째 행이 변수 이름(Header)으로 자동 지정된다.

```
% 헤더가 없는 경우  
T = readtable('data.csv', 'ReadVariableNames', false);  
  
% 특정 시트 (sheet 2)만 로드 (Excel)  
T = readtable('data.xlsx', 'Sheet', 2);
```

- 'FileType' 옵션을 통해 파일 형식을 강제 지정할 수 있다.

- **UCI Machine Learning Repository**: 학술용 표준 데이터셋 제공처. <https://archive.ics.uci.edu/>
- 머신러닝 및 데이터 과학 입문에 필수적인 데이터 집합.
- 예시: Iris, Wine, Adult, Housing.

실습: UCI Iris 데이터 직접 로드

- URL을 통해 인터넷에서 데이터를 직접 불러온다.

```
url = 'https://archive.ics.uci.edu/ml/machine-learning-databases/iris/iris.data';  
T = readtable(url, 'FileType', 'text');  
% 변수 이름 수동 지정  
T.Properties.VariableNames = {'SL','SW','PL','PW','Species'};  
head(T)
```

- **Kaggle**: 세계 최대의 데이터 과학 커뮤니티 및 경진대회 플랫폼. <https://www.kaggle.com/>
- 실무적이고 대규모인 데이터셋(Titanic, Netflix, COVID-19) 보유.
- 사용 절차: 다운로드 → 현재 폴더 복사 → `readtable`.

실습: Kaggle Titanic 데이터 불러오기

```
T = readtable('titanic_train.csv');  
% 기본 정보 요약  
summary(T)
```

- `summary` 함수를 통해 각 열의 데이터 타입과 기초 통계를 확인한다.

공개 데이터 사이트 (해외)

- Google Dataset Search <https://datasetsearch.research.google.com/>
- World Bank Open Data <https://data.worldbank.org/>
- data.gov (미국 정부 데이터) <https://www.data.gov/>
- EU Open Data Portal <https://data.europa.eu/>
- OpenML <https://www.openml.org/>
- Papers With Code (Datasets) <https://paperswithcode.com/datasets>
- AWS Open Data Registry <https://registry.opendata.aws/>
- Yahoo Finance <https://finance.yahoo.com/>
- NOAA Climate Data <https://www.noaa.gov/>
- ImageNet <https://www.image-net.org/>
- PhysioNet <https://physionet.org/>

공개 데이터 사이트 (국내)

- 공공데이터포털 <https://www.data.go.kr/>
- KOSIS (국가통계포털) <https://kosis.kr/>
- 한국은행 경제통계시스템 <https://ecos.bok.or.kr/>
- AI Hub <https://aihub.or.kr/>
- 서울 열린데이터광장 <https://data.seoul.go.kr/>
- 국가공간정보포털 <https://www.nsdi.go.kr/>

분석 결과 저장하기

- MATLAB 변수를 외부 파일로 내보낸다.

```
clc;  
writetable(T, 'processed_data.csv');  
writetable(T, 'results.xlsx', 'Sheet', 'Final');
```

%% Table 출력

%CSV → type, readtable 둘 다 가
능
xlsx 는 readtable 만 가능

```
type processed_data.csv  
readtable ('processed_data.csv')  
readtable('results.xlsx', 'Sheet', 'Final')
```

MATLAB 전용 형식 (.mat)

- save 함수를 통해 작업 공간(Workspace)의 변수를 그대로 저장한다.

```
save('my_project.mat', 'T', 'time', 'temp');
```

```
% 다시 불러오기
```

```
load('my_project.mat');
```

온라인 데이터 다운로드: webservice

- webservice 함수는 인터넷에 있는 파일을 로컬 컴퓨터로 다운로드한다.
- 이후 readtable, readmatrix 등으로 분석 가능하다.

```
filename = webservice('저장파일명', 'URL');
```

- 반환값: 다운로드된 파일의 이름
- 주로 CSV, TXT, 데이터셋 다운로드에 사용

websave + readtable 사용 예

- **목표:** 온라인 Wine 데이터를 다운로드 후 분석

```
url = ['https://archive.ics.uci.edu/ml/machine-learning-databases/' ...  
      'wine/wine.data'];  
  
% Step 1: 다운로드  
file = websave('wine_data.csv', url);  
  
% Step 2: 불러오기  
T = readtable(file, 'FileType','text', 'ReadVariableNames', false);  
  
% Step 3: 일부 데이터 확인  
head(T)
```

- **핵심 흐름:**

websave → readtable → 분석

데이터 로드 방법 비교 요약

함수	주 용도	비고
load	순수 수치 행렬	가장 빠름
readtable	혼합 데이터 (CSV)	가장 범용적
xlsread	구버전 Excel	현재는 지양
websave	온라인 파일 다운로드	자동화 가능

[실습 1] 자신만의 데이터 로드 루틴 만들기

- **목표:** 텍스트 파일을 직접 만들고 로드해본다.

```
% Step 1: 메모장에 아래 내용 입력 후 'test.txt' 저장
1, 10
2, 20
3, 30

% Step 2: MATLAB에서 로드
data = readmatrix('test.txt');
plot(data(:,1), data(:,2), '-o');
```

Part 2

데이터 구조와 Table 조작

Data Structures & Table Manipulation

Table 자료형의 장점

- 서로 다른 타입의 데이터(숫자, 문자열, 날짜)를 한 변수에 담을 수 있다.
- 각 열에 고유한 이름을 부여하여 가독성을 높인다.
- 엑셀의 데이터 시트와 유사한 구조로 설계되었다.

Table 변수(열) 접근 방식

- 점 연산자(.)를 사용하여 특정 열의 데이터를 벡터로 추출한다.

```
% 'Age' 열 데이터 전체 추출
```

```
age_vector = T.Age;
```

```
% 'Name' 열 데이터 전체 추출
```

```
name_list = T.Name;
```

Table에 변수 추가하기 (1)

```
%% 데이터 Matrix 생성 후 Table 변환한 후 변수추가하기
%% Step 1: 데이터 불러오기 또는 Matlab 내부에서 생성하기
(scores.dat 파일 생성)
clc;
scores = [ ...
    85  90  88;
    78  82  80;
    92  91  95;
    70  75  72;
    88  85  84
];

writematrix(scores, 'scores.dat', 'Delimiter', ' ');

%% Step 2: 파일 로드

A = load('scores.dat');
```

Table 변환 및 총점/평균 계산

```
% Step 3: Table로 변환
T_score = array2table(A, ...
    'VariableNames', {'Math', 'English', 'Science'});

% Step 4: 총점 및 평균 계산
T_score.Total = T_score.Math + T_score.English + T_score.Science;
T_score.Average = T_score.Total / 3;

% 결과 확인
disp(T_score)
```

Table에 변수 추가하기 (2)

- 데이터를 불러와서 사용할 수도 있지만 데이터를 생성해서 분석시에는 데이터 생성시 **matrix보다 table을 직접 생성하는 것이 권장된다.**
- 변수 이름을 명시적으로 부여할 수 있어 해석이 직관적이다.

```
% Table 직접 생성 후 변수추가하기
clc;
Math = [85;78;92;70;88];
English = [90;82;91;75;85];
Science = [88;80;95;72;84];

T_score1 = table(Math, English, Science);
T_score1.Total = T_score1.Math + T_score1.English + T_score1.Science;
T_score1.Average = T_score1.Total / 3;

disp(T_score1)
```

숫자와 문자열이 혼합된 Table 생성

- 다양한 자료형(숫자, 문자열, 논리값)을 하나의 table로 구성

%% 데이터 생성

```
ID      = [1; 2; 3; 4];  
Name     = ["Alice"; "Bob"; "Charlie"; "David"];  
Age      = [20; 25; 23; 22];  
Gender   = ["F"; "M"; "M"; "M"];  
Score    = [88.5; 92.0; 79.5; 85.0];  
Passed   = [true; true; false; true];
```

% table 생성

```
T_score2 = table(ID, Name, Age, Gender, Score, Passed)  
disp(T_score2)
```

참고) ' ' → char (문자 배열)

" " → string (문자열 객체, string array)

점수 데이터에서 조건 추출

- T_score에서 평균 점수가 90점 이상인 학생을 추출한다.

```
%% 평균 점수 90 이상 학생 추출
```

```
high_score = T_score(T_score.Average >= 90, :);
```

```
%% 결과 확인
```

```
disp(high_score)
```

Titanic 데이터에서 성별 추출

- T에서 성별이 여성(female)인 승객만 추출한다.

%% 여성 승객 추출, string compare (문자열 비교)의미

```
females = T(strcmp(T.Sex, 'female'), :);
```

%% 결과 확인

```
disp(females)
```

점 표기법을 이용한 변수 추출

설명: 변수명(column name)을 이용하여 특정 열 추출

```
% Name 변수 추출
```

```
T_score2.Name
```

```
% Score 변수 추출
```

```
T_score2.Score
```

```
% Passed 변수 추출
```

```
T_score2.Passed
```


중괄호를 이용한 데이터 추출

설명: 사용 → 실제 데이터 배열 반환

```
% Score 열의 실제 데이터
scoreData = T_score2(:, 'Score')

% Age와 Score 두 열의 실제 데이터
numericData = T_score2(:, {'Age', 'Score'})

% 일부 행 데이터
partialScore = T_score2(1:3, 'Score')
```

주의: table이 아닌 숫자 배열 반환

소괄호를 이용한 Table 부분 추출

설명: () 사용 → 결과가 table 형식 유지

```
% Score 열만 table로 추출
scoreTable = T_score2(:, 'Score')

% 여러 열 선택
selectedTable = T_score2(:, {'Name', 'Score', 'Passed'})

% 일부 행 + 일부 열
smallTable = T_score2(1:2, {'Name', 'Score'})
```

조건을 이용한 데이터 추출

설명: 조건식을 이용하여 행과 변수 선택

```
% 점수 85 이상
T_score2(T_score2.Score >= 85, :)

% 점수 85 이상 + 일부 변수
T_score2(T_score2.Score >= 85, {'Name', 'Score'})

% 통과한 학생 이름 (데이터 형태)
passedNames = T_score2{T_score2.Passed == true, 'Name'}

% 남학생의 Age, Score
maleData = T_score2(T_score2.Gender == "M", {'Age', 'Score'})
```

Cell 배열 (Cell Array)

- Table 은 주로 데이터를 분석하기 위해 사용하고 셀배열, 구조체배열은 데이터를 저장하기 위해 사용한다.
- 크기와 타입이 서로 다른 데이터를 저장하는 배열이다.
- 중괄호(\{\})를 사용하여 생성 및 색인한다.
- 예: 문장의 각 단어 저장, 다양한 크기의 행렬 저장.

```
C = {'Sejong', [1 2; 3 4], 3.14};
```

% 내용물 접근 (중괄호 사용)

```
val1 = C{1}; % 'Sejong'
```

```
val2 = C{2}; % 2x2 matrix
```

% 셀 자체 접근 (소괄호 사용)

```
sub_cell = C(1:2);
```

구조체 (Structure)

- 필드명(Field name)을 사용하여 데이터를 분류 저장한다.
- 연구 데이터 관리 시 매우 유용하다.
- 예: `student.name`, `student.id`, `student.gpa`.

```
S.name = 'Yoon';  
S.dept = 'AI';  
S.score = [90 85 95];  
  
% 필드 접근  
avg_score = mean(S.score);
```

- 행렬 연산이 필요한 경우 Table을 Matrix로 변환해야 한다.

```
% Table -> Array
```

```
A = table2array(T(:, 2:5));
```

```
% Array -> Table
```

```
T_new = array2table(A, 'VariableNames', {'V1', 'V2', 'V3', 'V4'});
```


- 특정 열의 값을 기준으로 전체 데이터를 정렬한다.

% 수학 점수 기준 내림차순 정렬

```
T_sorted = sortrows(T_score, 'Math', 'descend');
```

% 영어점수 기준 오름차순 정렬

```
T_sorted2 = sortrows(T_score, 'English', 'ascend');
```

[실습 2] 데이터 필터링 및 정렬

- **목표:** Iris 데이터에서 'Setosa' 품종만 추출하여 꽃잎 길이순으로 정렬한다.

```
clc;
```

```
% 1. 데이터 불러오기 (Iris 데이터에 텍스트가 들어 있으므로 확장자  
가 txt, dat, data 등의 경우는 FileType 지정부분 필수.)
```

```
T_iris = readtable('iris.csv');
```

```
%T_iris = readtable('iris.data', 'FileType', 'text');
```

```
% 2. 변수 이름 재지정
```

```
T_iris.Properties.VariableNames = {'SepalLength','SepalWidth','PetalLength',  
'PetalWidth','Species'};
```

```
% 3. logical index 생성
```

```
idx = strcmp(T_iris.Species, 'Iris-setosa');
```

```
% 4. 추출
```

```
setosa = T_iris(idx, :)
```

```
% 5. 정렬
```

```
result = sortrows(setosa, 'PetalLength', 'ascend');
```

```
disp(head(result));
```

[실습 2] 데이터 필터링 및 정렬

%또는 한번에 다음과 같이 할 수도 있다.

```
clc;  
setosa = T_iris(strcmp(T.Species, 'Iris-setosa'), :);  
result = sortrows(setosa, 'PetalLength', 'ascend')
```

Part 3

데이터 전처리 (Preprocessing)

Data Cleaning & Transformation

전처리(Preprocessing)의 목적

- **"Garbage In, Garbage Out"**: 데이터가 지저분하면 분석 결과도 믿을 수 없다.
- **목적:**
 - 결측치(NaN) 제거 및 대체
 - 이상치(Outlier) 탐지 및 정정
 - 데이터 정규화(Normalization)

Missing Values: 결측치 처리

- 결측치는 데이터가 비어 있거나 관측되지 않은 값을 의미한다.
- 숫자형 데이터에서는 주로 NaN으로 표현된다.
- table 데이터에서는 missing, 빈 문자열, NaN 등이 함께 나타날 수 있다.
- 결측치 처리는 데이터 분석 전 반드시 수행해야 하는 기본 전처리 과정이다.

주요 MATLAB 함수

- isnan: 숫자 배열에서 NaN 위치 찾기
- ismissing: table 또는 배열에서 결측값 찾기
- rmmissing: 결측값이 포함된 행 또는 열 제거
- fillmissing: 결측값을 특정 방법으로 채우기
- standardizeMissing: 특정 값을 결측값으로 변환

Missing Values 예제 1: 직접 데이터 만들기

Example 센서 온도 데이터에 일부 결측값이 포함되어 있다고 하자. 먼저 NaN의 위치를 찾고, 결측값의 개수를 계산한다.

```
clear; clc;                                % Clear workspace and command window

temp = [21.5 22.0 NaN 23.1 24.0 NaN 25.2 26.1]; % Temperature data

idx_missing = isnan(temp);                  % Find NaN positions
num_missing = sum(idx_missing);              % Count missing values

disp(idx_missing);                          % Display missing positions
fprintf('Number of missing values = %d\n', num_missing);
```

`isnan(temp)`의 결과는 `temp`와 같은 크기의 logical vector이다.

Missing Values 예제 2: 결측값 제거

Example 결측값이 포함된 숫자형 벡터에서 NaN을 제거하고, 정상 관측값만 이용하여 평균을 계산한다.

```
clear; clc;                                % Clear workspace and command window

temp = [21.5 22.0 NaN 23.1 24.0 NaN 25.2 26.1]; % Temperature data

temp_clean = temp(~isnan(temp));           % Remove NaN values

mean_temp = mean(temp_clean);              % Compute mean without missing values

disp(temp_clean);                          % Display cleaned data
fprintf('Mean temperature = %.2f\n', mean_temp);
```

`~isnan(temp)`는 결측값이 아닌 위치만 선택하는 logical indexing이다.

Missing Values 예제 3: 평균으로 채우기

Example 결측값을 제거하지 않고, 관측된 값들의 평균으로 결측값을 채운다. 이 방법은 데이터 길이를 유지해야 할 때 유용하다.

```
clear; clc;                                % Clear workspace and command window

temp = [21.5 22.0 NaN 23.1 24.0 NaN 25.2 26.1]; % Temperature data

mean_temp = mean(temp, 'omitnan'); % Compute mean ignoring NaN

temp_filled = temp;                        % Copy original data
temp_filled(isnan(temp_filled)) = mean_temp; % Replace NaN with mean

disp(temp_filled);                        % Display filled data
```

`mean(temp, 'omitnan')`은 NaN을 제외하고 평균을 계산한다.

Missing Values 예제 4: fillmissing 사용

Example fillmissing을 이용하면 결측값을 평균, 중앙값, 이전 값, 다음 값 등 다양한 방법으로 채울 수 있다.

```
clear; clc; % Clear workspace and command window

x = [10 12 NaN 15 NaN 18 20]; % Data with missing values

x_mean = fillmissing(x, 'constant', mean(x,'omitnan')); % Fill with mean
x_linear = fillmissing(x, 'linear'); % Fill by linear interpolation
x_previous = fillmissing(x, 'previous'); % Fill with previous value

disp(x_mean); % Display mean-filled data
disp(x_linear); % Display linearly filled data
disp(x_previous); % Display previous-filled data
```

시간 순서가 있는 데이터에서는 'linear' 또는 'previous' 방법이 자주 사용된다.

Missing Values 예제 5: 결측값과 보간

Example 시간에 따른 센서 데이터에서 일부 값이 빠진 경우, 관측된 점들 사이를 선형 보간하여 결측값을 복원한다.

```
clear; clc; % Clear workspace and command window

time = 1:10; % Time index
sensor = [5.1 5.4 NaN 6.0 6.3 NaN 7.1 7.4 NaN 8.0]; % Sensor data

valid = ~isnan(sensor); % Find observed values

sensor_interp = interp1(time(valid), sensor(valid), time, 'linear'); % Interpolation

plot(time, sensor, 'o', time, sensor_interp, '-','LineWidth',1.5);
xlabel('Time'); % Add x-axis label
ylabel('Sensor Value'); % Add y-axis label
legend('Observed','Interpolated'); % Add legend
grid on; % Add grid
```

Missing Values 예제 6: table 데이터 만들기

Example 학생 데이터 table을 직접 만들고, 일부 점수에 결측값을 넣어 결측치 탐지와 제거를 수행한다.

```
clear; clc; % Clear workspace and command window

Name = {'A','B','C','D','E','F'}; % Student names
Math = [85; 90; NaN; 76; 88; NaN]; % Math scores
Science = [92; NaN; 81; 79; 85; 90]; % Science scores

T_score = table(Name, Math, Science); % Create table

missing_table = ismissing(T_score); % Find missing values in table
T_clean = rmmissing(T_score); % Remove rows with missing values

disp(missing_table); % Display missing positions
disp(T_clean); % Display cleaned table
```

Missing Values 예제 7: table에서 결측값 채우기

Example table의 숫자형 변수에 포함된 결측값을 각 변수의 평균으로 채운다.

```
clear; clc; % Clear workspace and command window

Name = {'A','B','C','D','E','F'}; % Student names
Math = [85; 90; NaN; 76; 88; NaN]; % Math scores
Science = [92; NaN; 81; 79; 85; 90]; % Science scores

T_score = table(Name, Math, Science); % Create table

T_score.Math = fillmissing(T_score.Math, 'constant', ...
    mean(T_score.Math,'omitnan')); % Fill Math missing values

T_score.Science = fillmissing(T_score.Science, 'constant', ...
    mean(T_score.Science,'omitnan')); % Fill Science missing values

disp(T_score); % Display filled table
```

Titanic 데이터 예제 1: 파일 불러오기

Example 현재 MATLAB 작업 폴더에 `titanic.csv` 파일이 있다고 가정한다. 이 파일을 `table`로 불러온 뒤 변수 이름과 데이터 일부를 확인한다.

```
clear; clc; % Clear workspace and command window

T_titanic = readtable('titanic.csv'); % Read Titanic data as table

disp(T_titanic.Properties.VariableNames); % Display variable names
head(T_titanic); % Display first few rows
```

파일마다 변수 이름이 다를 수 있으므로 `Properties.VariableNames`를 먼저 확인하는 것이 중요하다.

Titanic 데이터 예제 2: 결측값 개수 확인

Example Titanic 데이터에서 Age 변수의 결측값 개수를 확인한다.

```
clear; clc; % Clear workspace and command window

T_titanic = readtable('titanic.csv'); % Read Titanic data as table

missing_age = ismissing(T_titanic.Age); % Find missing Age values
num_missing_age = sum(missing_age); % Count missing Age values

fprintf('Number of missing Age values = %d\n', num_missing_age);
```

`ismissing(T_titanic.Age)`는 Age 열에서 결측값 위치를 logical vector로 반환한다.

Titanic 데이터 예제 3: Age 결측 행 제거

Example Age가 결측값인 승객을 제거한 뒤, 생존 여부별 평균 나이를 계산한다.

```
clear; clc; % Clear workspace and command window

T_titanic = readtable('titanic.csv'); % Read Titanic data as table

T_titanic_clean = rmmissing(T_titanic, ...
    'DataVariables','Age'); % Remove rows with missing Age

G_age = groupsummary(T_titanic_clean, ...
    'Survived', 'mean', 'Age'); % Mean Age by Survived

disp(G_age); % Display result
```


Titanic 데이터 예제 4: Age 평균으로 채우기

Example Age 결측값을 전체 승객의 평균 나이로 채운다. 이 방법은 행을 삭제하지 않고 전체 데이터 개수를 유지한다.

```
clear; clc;                                % Clear workspace and command window

T_titanic = readtable('titanic.csv'); % Read Titanic data as table

mean_age = mean(T_titanic.Age, 'omitnan'); % Mean Age ignoring missing

T_titanic.Age = fillmissing(T_titanic.Age, ...
    'constant', mean_age);                % Fill missing Age with mean

num_missing_after = sum(ismissing(T_titanic.Age)); % Check missing values

fprintf('Missing Age after filling = %d\n', num_missing_after);
```

Titanic 데이터 예제 5: 그룹별 평균으로 채우기

Example 전체 평균 대신 성별(Sex) 평균 나이를 이용하여 Age 결측값을 채운다. 그룹별 평균 대체는 단순 전체 평균보다 더 세밀한 방법이다.

```
clear; clc; % Clear workspace and command window

T_titanic = readtable('titanic.csv'); % Read Titanic data as table

idx_male = strcmp(T_titanic.Sex,'male'); % Male rows
idx_female = strcmp(T_titanic.Sex,'female'); % Female rows

mean_age_male = mean(T_titanic.Age(idx_male), 'omitnan'); % Male mean Age
mean_age_female = mean(T_titanic.Age(idx_female), 'omitnan'); % Female mean

idx_missing_age = ismissing(T_titanic.Age); % Missing Age rows

T_titanic.Age(idx_missing_age & idx_male) = mean_age_male; % Fill male Age
T_titanic.Age(idx_missing_age & idx_female) = mean_age_female; % Fill female

disp(groupsummary(T_titanic, 'Sex', 'mean', 'Age'));
```

Titanic 데이터 예제 6: 결측 Cabin 처리

Example Cabin처럼 결측값이 많은 문자형 변수는 분석 목적에 따라 제거하거나, 결측 여부 자체를 새로운 변수로 만들 수 있다.

```
clear; clc; % Clear workspace and command window

T_titanic = readtable('titanic.csv'); % Read Titanic data as table

T_titanic.HasCabin = ~ismissing(T_titanic.Cabin); % Cabin observed or not

G_cabin = groupsummary(T_titanic, ...
    'HasCabin', 'mean', 'Survived'); % Survival rate by Cabin availability

disp(G_cabin); % Display result
```

결측값을 무조건 삭제하기보다, 결측 여부가 의미 있는 정보인지 확인할 필요가 있다.

Titanic 데이터 예제 7: 여러 변수 결측 행 제거

Example 분석에 필요한 변수 Age, Fare, Embarked 중 하나라도 결측값이 있으면 해당 행을 제거한다.

```
clear; clc;                                % Clear workspace and command window

T_titanic = readtable('titanic.csv'); % Read Titanic data as table

T_selected = rmmissing(T_titanic, ...
    'DataVariables', {'Age','Fare','Embarked'}); % Remove rows with missing

fprintf('Original rows = %d\n', height(T_titanic));
fprintf('Remaining rows = %d\n', height(T_selected));

summary(T_selected);                        % Summarize cleaned table
```

Titanic 데이터 예제 8: 전처리 결과 저장

Example 결측값 처리가 끝난 Titanic table을 새 CSV 파일로 저장한다. 전처리된 파일은 이후 분석에서 다시 사용할 수 있다.

```
clear; clc; % Clear workspace and command window

T_titanic = readtable('titanic.csv'); % Read Titanic data as table

mean_age = mean(T_titanic.Age, 'omitnan'); % Mean Age
T_titanic.Age = fillmissing(T_titanic.Age, 'constant', mean_age); % Fill Age

T_titanic.HasCabin = ~ismissing(T_titanic.Cabin); % Add Cabin indicator

writetable(T_titanic, 'titanic_preprocessed.csv'); % Save table

disp('Saved titanic_preprocessed.csv');
```

이상치 (Outlier) 탐지

- 정의: 다른 관측치와 현저하게 다른 비정상적인 값.
- 판단 기준:
 - 통계적 기준: 3σ (표준편차) 이상 떨어진 값.
 - 사분위수 기준: IQR의 1.5배 이상 벗어난 값.

이상치 제거 루틴 (논리 연산)

- 논리 연산자를 결합하여 이상치를 필터링한다.

```
clc;

% 1. 데이터 불러오기
T_iris = readtable('iris.csv');
T_iris.Properties.VariableNames = {'SepalLength', 'SepalWidth', 'PetalLength', 'PetalWidth'};

% 2. PetalWidth 변수 추출
PetalWidth = T_iris.PetalWidth;

% 3. 평균과 표준편차 계산
mu = mean(PetalWidth);
sig = std(PetalWidth);

% 4. 3σ 기준으로 이상치 제거
clean_PetalWidth = PetalWidth(abs(PetalWidth - mu) <= 3*sig)
```

루프를 이용한 이상치 정제 (1/2)

```
clc;

T_iris_clean = T_iris;           % Table 복사(원본 보존위해)

PL = T_iris_clean.PetalLength;   % PetalLength 변수 추출

mu = mean(PL);                   % 평균 계산
sig = std(PL);                   % 표준편차 계산

[R, ~] = size(PL);               % 데이터 개수 (행 개수)

for i = 1:R                       % 각 데이터에 대해 반복
    if abs(PL(i) - mu) > 3*sig     % 평균에서  $3\sigma$  초과 여부 판단
        PL(i) = NaN;            % 이상치를 NaN으로 처리
    end
end

T_iris_clean.PetalLength = PL     % 새로운 테이블에 반영
```


루프를 이용한 이상치 제거 (2/2)

```
clc;

T_iris_clean = T_iris;           % 원본 테이블 복사
SW = T_iris_clean.SepalWidth;    % SepalWidth 추출

Q1 = quantile(SW, 0.25);         % 1사분위수
Q3 = quantile(SW, 0.75);         % 3사분위수
IQR_val = Q3 - Q1;               % IQR 계산
lower = Q1 - 1.5*IQR_val;        % 하한 경계
upper = Q3 + 1.5*IQR_val;        % 상한 경계

[R, ~] = size(SW);               % 데이터 개수
for i = 1:R                       % 각 데이터 반복
    if SW(i) < lower || SW(i) > upper % 이상치 확인
        SW(i) = NaN;              % 이상치 NaN 처리
    end
end

T_iris_clean.SepalWidth = SW      % 새 테이블에 반영
```

루프를 이용한 이상치 정제 (2/2)

- 다차원 배열에서 각 원소를 검사할 때 중첩 루프를 사용한다.

```
clc;

A = [3   -1   5;           % 예제 행렬 생성
     -2   4  -6;
      7  -3   2];

for i = 1:size(A, 1)       % 행 개수만큼 반복
    for j = 1:size(A, 2)   % 열 개수만큼 반복
        if A(i,j) < 0      % 현재 원소가 음수이면
            A(i,j) = 0;    % 0으로 변경
        end
    end
end
A
```

데이터 정규화 (Normalization, Min-Max Scaling)

- 서로 다른 단위의 데이터를 0 ~ 1 사이로 변환한다.

```
clc;

data = [10  20  30  40  50];           % 예제 데이터 생성

mn = min(data);                        % 최소값 계산
mx = max(data);                        % 최대값 계산

norm_data = (data - mn) ./ (mx - mn); % Min-Max 정규화 (0~1 범위로 변환)
```

- 연산 시 ./와 .- 등 원소 단위 연산자 사용에 주의한다.

데이터 표준화 (Standardization)

- 평균을 0, 표준편차를 1로 맞춘다.

```
mu = mean(data);  
sig = std(data);  
std_data = (data - mu) ./ sig;  
  
% MATLAB 내장 함수 활용  
std_data = zscore(data);
```

[실습 3] Titanic 데이터 정제

- **목표:** Titanic 데이터에서 Age의 결측치를 평균으로 채우고, 운임(Fare)의 이상치를 제거한다.

```
clc;

T_titanic = readtable('titanic.csv')           % 데이터 불러오기
T_titanic.Age = fillmissing(T_titanic.Age, ... % Age 결측치
    'constant', mean(T_titanic.Age, 'omitnan')); % NaN 제외 평균값
으로 채움

mu_f = mean(T_titanic.Fare);                    % Fare 평균 계산
sig_f = std(T_titanic.Fare);                    % Fare 표준편
차 계산

T_titanic_final = T_titanic( ...                % 새테이블 생성
    abs(T_titanic.Fare)- mu_f <= 3*sig_f, :);   % 이상치제거
```

Part 4

기술통계 및 탐색적 분석

Descriptive Statistics & EDA

- mean: 평균
- median: 중앙값
- std: 표준편차
- var: 분산
- min / max: 최솟값 / 최댓값
- mode: 최빈값

그룹별 통계 계산 (groupsummary)

- 카테고리별로 통계 지표를 한 번에 계산한다.

```
clc;

Name = ["Alice"; "Bob"; "Charlie"; "David"; "Eva"; "Frank"];
Grade = ["A"; "A"; "B"; "B"; "C"; "C"];           % 그룹 기준
Math = [90; 85; 78; 82; 70; 75];

T_score = table(Name, Grade, Math);                % table 생성

stats = groupsummary(T_score, 'Grade', ...         % Grade기준 그룹화
    {'mean','std'}, 'Math');                       % Math의 평균과 표준
                                                    % Math의
편차

disp(stats);                                       % 결과 출력
```


상관관계 분석 (corrcoef)

- 두 변수 사이의 선형적 관계 강도를 측정한다.

```
clc;

Name = ["Alice"; "Bob"; "Charlie"; "David"; "Eva"];
Grade = ["A"; "A"; "B"; "B"; "C"];
Math = [90; 85; 78; 92; 88];

T_score = table(Name, Grade, Math);
Science = [88; 82; 75; 95; 90];    % 과학 점수 생성
T_score.Science = Science          % 기존 table에 Science 열 추가

R = corrcoef(T_score.Math, T_score.Science); % Math와 Science 상
관계수 계산

fprintf('상관계수: %.2f\n', R(1, 2));    % 상관계수 출력
```

- 1에 가까울수록 양의 상관관계, -1에 가까울수록 음의 상관관계.

다변량 분석: plotmatrix

- 모든 변수 쌍의 산점도를 한꺼번에 그린다.

```
clc;

Name      = ["Alice"; "Bob"; "Charlie"; "David"; "Eva"];
Math      = [90; 85; 78; 92; 88];
Science   = [88; 82; 75; 95; 90];
English   = [85; 80; 70; 90; 87];
History   = [82; 78; 72; 88; 85];

T_score = table(Name, Math, Science, English, History);

data_vars = table2array(T_score(:, 2:5));

                                % 숫자 변수만 배열로 변환
plotmatrix(data_vars);          % 변수 간 산점도 행렬 출력

%plotmatrix(T_score{:, ["Math","Science","English","History"]})
                                %array 만들지않고 바로 plot할 때 이용
```

- 논리 변수를 인덱스로 사용하여 특정 집단의 평균 구하기.

```
is_setosa = strcmp(T_iris.Species, 'Iris-setosa');  
avg_sl = mean(T_iris.SepalLength(is_setosa));
```

[실습 4] 데이터 요약 실습

- **목표:** Titanic 데이터에서 생존 여부(Survived)별 평균 나이를 계산한다.

```
clc;

T_titanic = readtable('titanic.csv'); % titanic.csv파일을 테이블로

T_titanic_clean = rmmissing(T_titanic, ...
    'DataVariables','Age'); % Age 변수에 결측치가 있는 행 제거

G = groupsummary(T_titanic_clean, ...
    'Survived', 'mean', 'Age'); % Survived 기준으로 Age 평균 계산
disp(G); % 결과 출력
```

Part 6

종합 실습문제

Final Practice

실습문제 1: `txt` 파일 생성과 시각화

MATLAB 안에서 직접 수치 데이터를 생성한 뒤, 이를 `data.txt` 파일로 저장하고 다시 불러와 그래프로 나타내시오.

- (1) $x = 1, 2, \dots, 50$ 인 열벡터를 만들고, $y = 2x + \epsilon$ 형태의 데이터를 생성하시오. 여기서 ϵ 은 `randn`을 이용한 잡음으로 생성하시오.
- (2) x 와 y 를 하나의 행렬로 묶어 `data.txt` 파일로 저장하시오.
- (3) `data.txt` 파일을 다시 불러와 x - y 선 그래프를 그리시오.

실습문제 2: students.csv 생성과 로드

MATLAB 안에서 학생 20명의 성적 데이터를 직접 생성한 뒤, CSV 파일로 저장하고 다시 불러오시오.

- (1) 학생 이름은 Student1, Student2, ..., Student20 형식으로 생성하시오.
- (2) Math, English, Science 점수는 각각 60점 이상 100점 이하의 정수 난수로 생성하시오.
- (3) 생성한 table을 students.csv로 저장한 뒤 다시 불러와 처음 5행을 출력하시오.

실습문제 3: Table 열 접근과 평균 계산

students.csv에서 불러온 학생 성적 table T를 이용하여 각 과목의 평균 점수를 계산하시오.

- (1) T.Math, T.English, T.Science를 이용하여 각 과목 점수 열에 접근하시오.
- (2) 각 과목의 평균 점수를 각각 계산하시오.
- (3) 계산된 평균 점수를 하나의 table로 정리하여 출력하시오.

실습문제 4: Table에 총점과 평균 열 추가

학생 성적 table T에 총점과 평균 점수를 새로운 열로 추가하시오.

- (1) Math, English, Science를 더하여 Total 열을 추가하시오.
- (2) 세 과목 평균을 계산하여 Average 열을 추가하시오.
- (3) 수정된 table의 처음 5행을 출력하시오.

실습문제 5: 조건 필터링과 정렬

학생 성적 table T에서 조건을 만족하는 학생만 추출하고 평균 점수 기준으로 정렬하시오.

- (1) 수학 점수가 90점 이상인 학생을 추출하시오.
- (2) 평균 점수가 85점 이상인 학생을 추출하시오.
- (3) 두 조건을 동시에 만족하는 학생을 추출한 뒤, 평균 점수 기준 내림차순으로 정렬하시오.

실습문제 6: 처리된 성적 데이터 저장과 재로드

총점과 평균이 추가된 학생 성적 데이터를 새로운 CSV 파일로 저장하고 다시 불러오시오.

- (1) 현재 table T를 `processed_students.csv` 파일로 저장하시오.
- (2) 저장된 파일을 다시 `readtable`로 불러오시오.
- (3) 다시 불러온 table의 변수 이름과 처음 5행을 확인하시오.

실습문제 7: websave를 이용한 Wine 데이터 다운로드

UCI Wine 데이터를 MATLAB 안에서 다운로드한 뒤 table로 불러오시오.

- (1) UCI Wine 데이터 URL을 변수 `url`에 저장하시오.
- (2) `websave`를 이용하여 데이터를 `wine.csv` 파일로 저장하시오.
- (3) 저장된 `wine.csv` 파일을 `readtable`로 불러오고 변수 이름을 지정하시오.

실습문제 8: 결측치 생성과 평균 대체

학생 성적 데이터에 의도적으로 결측치를 만든 뒤, 각 과목 평균으로 대체하시오.

- (1) Math의 3번째 값, English의 7번째 값, Science의 12번째 값을 NaN으로 바꾸시오.
- (2) 각 과목의 결측치 개수를 계산하시오.
- (3) 각 과목의 결측치를 해당 과목 평균으로 대체하시오.

실습문제 9: 센서 데이터 생성과 이상치 처리

시간에 따라 변화하는 온도 센서 데이터를 생성하고, 일부 이상치를 찾아 제거하시오.

- (1) 시간 $t = 1, 2, \dots, 100$ 에 대해 온도 데이터 `temp`를 생성하시오.
- (2) 20번째, 50번째, 80번째 위치에 비정상적으로 큰 값을 넣어 이상치를 만드시오.
- (3) 평균에서 3표준편차를 초과하여 벗어난 값을 NaN으로 바꾸고 그래프로 비교하시오.

실습문제 10: 정규화와 표준화 비교

학생들의 평균 점수 `Average`를 이용하여 정규화와 표준화를 비교하시오.

- (1) `Average`를 0과 1 사이로 Min-Max 정규화하시오.
- (2) `Average`를 평균 0, 표준편차 1이 되도록 Z-score 표준화하시오.
- (3) 원래 평균 점수, 정규화 값, 표준화 값을 하나의 table로 정리하시오.

실습문제 11: 그룹별 성적 통계 분석

학생 20명을 두 개의 반으로 나누고, 반별 평균 점수를 비교하시오.

- (1) 앞의 10명은 ClassA, 뒤의 10명은 ClassB로 표시하는 Class 열을 추가하시오.
- (2) Class별 Average의 평균과 표준편차를 계산하시오.
- (3) Class별 평균 점수 분포를 boxplot으로 나타내시오.

실습문제 12: Wine 데이터 상관관계와 산점도

다운로드한 Wine 데이터를 이용하여 변수 간 관계를 분석하시오.

- (1) Alcohol, MalicAcid, Ash, ColorIntensity 네 변수를 선택하시오.
- (2) 선택한 네 변수의 상관계수 행렬을 계산하시오.
- (3) 선택한 네 변수에 대해 산점도 행렬을 그리시오.

실습문제 13: UCI Auto MPG 데이터 분석

UCI Auto MPG 데이터를 다운로드하여 자동차 연비와 주요 변수의 관계를 분석하시오.

- (1) websave를 이용하여 UCI Auto MPG 데이터를 다운로드하시오.
- (2) mpg, horsepower, weight, acceleration 변수를 포함하는 table을 만드시오.
- (3) 결측값을 제거한 뒤, weight와 mpg의 산점도를 그리고 상관계수를 계산하시오.

실습문제 14: UCI Breast Cancer Wisconsin 데이터 분석

UCI Breast Cancer Wisconsin Diagnostic 데이터를 다운로드하여 진단 그룹별 특성을 비교하시오.

- (1) WDBC 데이터를 다운로드하고 table로 불러오시오.
- (2) Diagnosis가 M인 경우와 B인 경우를 구분하시오.
- (3) 진단 그룹별 RadiusMean, TextureMean, AreaMean의 평균을 계산하시오.

실습문제 15: Kaggle Titanic 데이터 분석

Kaggle Titanic train.csv 파일을 다운로드하여 생존 여부에 따른 승객 특성을 분석하시오.

- (1) Kaggle에서 train.csv 파일을 다운로드하여 현재 MATLAB 폴더에 저장하시오.
- (2) readtable로 데이터를 불러오고, Age의 결측치를 평균으로 대체하시오.
- (3) 성별과 객실 등급별 생존율을 계산하고 막대그래프로 나타내시오.

코드 답안 1: txt 파일 생성과 시각화

```
x = (1:50)';  
y = 2*x + randn(50,1);  
  
data = [x y];  
  
writematrix(data, 'data.txt', 'Delimiter', ' ');  
  
A = load('data.txt');  
  
x_loaded = A(:,1);  
y_loaded = A(:,2);  
  
plot(x_loaded, y_loaded, '-o')  
grid on  
xlabel('x')  
ylabel('y')  
title('Data Loaded from data.txt')
```

코드 답안 2: students.csv 생성과 로드

```
Name = strings(20,1);

for i = 1:20
    Name(i) = "Student" + i;
end

Math = randi([60 100], 20, 1);
English = randi([60 100], 20, 1);
Science = randi([60 100], 20, 1);

T = table(Name, Math, English, Science);

writetable(T, 'students.csv');

T = readtable('students.csv');

disp(T(1:5, :))
```

코드 답안 3: Table 열 접근과 평균 계산

```
math_score = T.Math;
english_score = T.English;
science_score = T.Science;

mean_math = mean(math_score);
mean_english = mean(english_score);
mean_science = mean(science_score);

MeanTable = table(mean_math, mean_english, mean_science);

disp(MeanTable)
```

코드 답안 4: Table에 총점과 평균 열 추가

```
T.Total = T.Math + T.English + T.Science;  
  
T.Average = T.Total / 3;  
  
disp(T(1:5, :))
```


코드 답안 5: 조건 필터링과 정렬

```
top_math = T(T.Math >= 90, :);  
  
high_average = T(T.Average >= 85, :);  
  
selected = T(T.Math >= 90 & T.Average >= 85, :);  
  
selected_sorted = sortrows(selected, 'Average', 'descend');  
  
disp(top_math)  
disp(high_average)  
disp(selected_sorted)
```

코드 답안 6: 처리된 성적 데이터 저장과 재로드

```
writetable(T, 'processed_students.csv');  
  
T_processed = readtable('processed_students.csv');  
  
disp(T_processed.Properties.VariableNames)  
  
disp(T_processed(1:5, :))
```

코드 답안 7: websave를 이용한 Wine 데이터 다운로드

```
url = ['https://archive.ics.uci.edu/ml/machine-learning-databases/' ...  
      'wine/wine.data'];  
  
file = websave('wine.csv', url);  
  
Wine = readtable(file, 'FileType', 'text', ...  
                'ReadVariableNames', false);  
  
Wine.Properties.VariableNames = {'Class','Alcohol','MalicAcid', ...  
                                'Ash','Alcalinity','Magnesium','Phenols','Flavanoids', ...  
                                'Nonflavanoid','Proanthocyanins','ColorIntensity', ...  
                                'Hue','OD280','Proline'};  
  
disp(Wine(1:5, :))
```

코드 답안 8: 결측치 생성과 평균 대체

```
T_missing = T;

T_missing.Math(3) = NaN;
T_missing.English(7) = NaN;
T_missing.Science(12) = NaN;

num_math_nan = sum(isnan(T_missing.Math));
num_english_nan = sum(isnan(T_missing.English));
num_science_nan = sum(isnan(T_missing.Science));

fprintf('Math NaN: %d\n', num_math_nan)
fprintf('English NaN: %d\n', num_english_nan)
fprintf('Science NaN: %d\n', num_science_nan)

T_missing.Math = fillmissing(T_missing.Math, ...
    'constant', mean(T_missing.Math, 'omitnan'));
T_missing.English = fillmissing(T_missing.English, ...
    'constant', mean(T_missing.English, 'omitnan'));
T_missing.Science = fillmissing(T_missing.Science, ...
    'constant', mean(T_missing.Science, 'omitnan'));
```

코드 답안 9: 센서 데이터 생성과 이상치 처리

```
t = (1:100)';

temp = 25 + 2*sin(t/10) + randn(100,1);

temp([20 50 80]) = [50 55 60];

mu = mean(temp);
sig = std(temp);

idx_outlier = abs(temp - mu) > 3*sig;

temp_clean = temp;
temp_clean(idx_outlier) = NaN;

plot(t, temp, '-o')
hold on
plot(t, temp_clean, '-x')
grid on
xlabel('Time')
ylabel('Temperature')
legend('Original', 'Cleaned')
```

코드 답안 10: 정규화와 표준화 비교

```
avg = T.Average;  
  
avg_minmax = (avg - min(avg)) ./ (max(avg) - min(avg));  
  
avg_zscore = (avg - mean(avg)) ./ std(avg);  
  
Result = table(avg, avg_minmax, avg_zscore, ...  
    'VariableNames', {'Average', 'MinMax', 'Zscore'});  
  
disp(Result)
```

코드 답안 11: 그룹별 성적 통계 분석

```
Class = strings(height(T),1);

Class(1:10) = "ClassA";
Class(11:20) = "ClassB";

T.Class = Class;

G = groupsummary(T, 'Class', {'mean','std'}, 'Average');

disp(G)

boxplot(T.Average, T.Class)
xlabel('Class')
ylabel('Average')
title('Average Score by Class')
grid on
```

코드 답안 12: Wine 데이터 상관관계와 산점도

```
X = table2array(Wine(:, ...  
    {'Alcohol', 'MalicAcid', 'Ash', 'ColorIntensity'}));  
  
R = corrcoef(X);  
  
disp(R)  
  
plotmatrix(X)  
title('Scatter Plot Matrix for Wine Data')
```


코드 답안 13: UCI Auto MPG 데이터 다운로드 (1/4)

```
%% Step 1: Auto MPG CSV 파일 다운로드

url = ['https://raw.githubusercontent.com/mwaskom/' ...
       'seaborn-data/master/mpg.csv'];

file = websave('auto_mpg.csv', url);

%% Step 2: CSV 파일을 table로 불러오기

Auto = readtable(file);

%% Step 3: 일부 데이터 확인

disp(Auto(1:5, :))
```

코드 답안 13: 필요한 변수 선택 및 CSV 저장(2/4)

```
%% Step 4: 필요한 변수만 선택

Auto_small = Auto(:, ...
    {'mpg', 'horsepower', 'weight', 'acceleration'});

%% Step 5: 선택한 데이터를 CSV로 저장

writetable(Auto_small, 'auto_mpg_selected.csv');

%% Step 6: 저장한 CSV를 다시 table로 불러오기

Auto_small = readtable('auto_mpg_selected.csv');

disp(Auto_small(1:5, :))
```

코드 답안 13: 결측값 제거(3/4)

```
%% Step 7: horsepower 결측값 제거

Auto_clean = Auto_small( ...
    ~isnan(Auto_small.horsepower), :);

disp(Auto_clean(1:5, :))
```

코드 답안 13: 산점도와 상관계수(4/4)

```
%% Step 8: weight와 mpg의 산점도

plot(Auto_clean.weight, Auto_clean.mpg, 'o')
grid on
xlabel('Weight')
ylabel('MPG')
title('Auto MPG: Weight vs MPG')

%% Step 9: 상관계수 계산

R = corrcoef(Auto_clean.weight, Auto_clean.mpg);

fprintf('Correlation = %.3f\n', R(1,2))
```

코드 답안 14: WDBC 데이터 다운로드 및 로드(1/3)

```
%% Step 1: WDBC CSV 다운로드

url = ['https://raw.githubusercontent.com/selva86/' ...
      'datasets/master/BreastCancer.csv'];

file = websave('wdbc.csv', url);

%% Step 2: table로 불러오기

WDBC = readtable(file);

disp(WDBC(1:5, :))
```

코드 답안 14: 진단 그룹 구분(2/3)

```
%% Step 3: Diagnosis가 M / B 구분

M_group = WDBC(strcmp(WDBC.diagnosis, 'M'), :);
B_group = WDBC(strcmp(WDBC.diagnosis, 'B'), :);

disp(M_group(1:5, :))
disp(B_group(1:5, :))
```

코드 답안 14: 그룹별 평균 계산(3/3)

```
%% Step 4: 필요한 변수 선택

WDBC_small = WDBC(:, ...
    {'radius_mean', 'texture_mean', 'area_mean', 'diagnosis'});

%% Step 5: 그룹별 평균 계산

G = groupsummary(WDBC_small, 'diagnosis', ...
    'mean', {'radius_mean', 'texture_mean', 'area_mean'});

disp(G)
```

코드 답안 15: Titanic 데이터 로드(1/4)

```
%% Step 1: CSV 파일 불러오기
```

```
T = readtable('train.csv');
```

```
disp(T(1:5, :))
```


코드 답안 15: 결측값 처리(2/4)

```
%% Step 2: Age 결측값 평균으로 대체

T.Age = fillmissing(T.Age, ...
    'constant', mean(T.Age, 'omitnan'));

disp(T(1:5, :))
```

코드 답안 15: 성별별 생존율(3/4)

```
%% Step 3: 성별별 생존율
```

```
G1 = groupsummary(T, 'Sex', 'mean', 'Survived');
```

```
disp(G1)
```

코드 답안 15: 객실 등급별 생존율 + 그래프(4/4)

```
%% Step 4: 객실 등급별 생존율

G2 = groupsummary(T, 'Pclass', 'mean', 'Survived');

disp(G2)

%% Step 5: 막대그래프

bar(G2.Pclass, G2.mean_Survived)

grid on
xlabel('Passenger Class')
ylabel('Survival Rate')
title('Titanic Survival Rate by Class')
```