

Probability and Statistics

Chapter 10. One- and Two-Sample Tests of Hypotheses

Jin Hee Yoon

Spring, 2026

Dept. of Artificial Intelligence and Information Technology

Sejong University

Chapter Overview

- 10.1 Statistical Hypotheses: General Concepts
- 10.2 Testing a Statistical Hypothesis
- 10.3 The Use of P-Values for Decision Making
- 10.4 Single Sample: Tests Concerning a Single Mean
- 10.5 Two Samples: Tests on Two Means
- 10.6 Choice of Sample Size for Testing Means
- 10.7 Graphical Methods for Comparing Means
- 10.8 One Sample: Test on a Single Proportion
- 10.9 Two Samples: Tests on Two Proportions
- 10.10 One- and Two-Sample Tests Concerning Variances
- 10.11 Goodness-of-Fit Test
- 10.12 Test for Independence
- 10.13 Test for Homogeneity

10.1 Statistical Hypotheses: General Concepts

10.1 Statistical Hypotheses: General Concepts

Statistical inference is not only about estimating a parameter. Often we need a data-based decision about a scientific or engineering claim.

Statistical hypothesis: an assertion or conjecture concerning one or more populations.

- Medical example: Does coffee drinking increase cancer risk?
- Engineering example: Are two gauges different in accuracy?
- Social science example: Are blood type and eye color independent?

중요 내용 정리: hypothesis testing은 표본자료를 이용하여 모집단에 대한 주장을 기각할지 판단하는 절차이다.

Sample Evidence and Rejection

The truth or falsity of a statistical hypothesis is usually not known with certainty, because observing the entire population is impractical.

Sample evidence that is inconsistent with the stated hypothesis leads to rejection of the hypothesis.

- Rejection means the observed sample result would be very unlikely if the hypothesis were true.
- Nonrejection does not prove the hypothesis true.

중요 내용 정리: “reject”는 강한 결론이지만, “fail to reject”는 단지 증거가 부족하다는 뜻이다.

Null and Alternative Hypotheses

- **Null hypothesis** H_0 : the hypothesis to be tested; often status quo.
- **Alternative hypothesis** H_1 : the claim or direction supported when H_0 is rejected.

Typical conclusion:

- reject H_0 in favor of H_1 because the data give sufficient evidence;
- fail to reject H_0 because the data do not give sufficient evidence.

중요 내용 정리: 통계적 검정에서는 보통 H_0 를 “accept”한다고 말하지 않고, “fail to reject H_0 ”라고 표현한다.

Jury Trial Analogy

A jury trial gives a useful analogy for hypothesis testing.

H_0 : defendant is innocent, H_1 : defendant is guilty.

- Evidence must support H_1 beyond a reasonable doubt.
- Failure to reject H_0 does not prove innocence.
- It only means the evidence is insufficient for conviction.

중요 내용 정리: hypothesis testing의 기본 구조는 “기존 주장 유지”와 “새로운 주장에 대한 증거” 사이의 판단이다.

10.2 Testing a Statistical Hypothesis

10.2 Testing a Statistical Hypothesis

A new vaccine is compared with a vaccine known to be 25% effective after 2 years. Let X be the number protected among $n = 20$ people.

$$H_0 : p = 0.25, \quad H_1 : p > 0.25.$$

Decision rule:

- If $x > 8$, reject H_0 .
- If $x \leq 8$, fail to reject H_0 .

중요 내용 정리: critical region은 H_0 가 맞다고 보기 어려운 표본값들의 영역이다.

Test Statistic and Critical Region

Test statistic: a statistic used to decide whether to reject H_0 .

For the vaccine example, the test statistic is the binomial random variable X .

- Possible values: $0, 1, 2, \dots, 20$.
- Critical region: $X > 8$.
- Critical value: 8.

중요 내용 정리: critical value는 nonrejection region과 rejection region을 나누는 경계값이다.

Type I and Type II Errors

- **Type I error:** reject H_0 when H_0 is true.
- **Type II error:** fail to reject H_0 when H_0 is false.

	H_0 true	H_0 false
Fail to reject H_0	correct decision	Type II error
Reject H_0	Type I error	correct decision

중요 내용 정리: 검정은 항상 잘못된 결론의 가능성을 포함한다.

Level of Significance

The probability of committing a Type I error is denoted by α .

$$\alpha = P(\text{Type I error}) = P(\text{reject } H_0 \mid H_0 \text{ true}).$$

For the vaccine example,

$$\alpha = P(X > 8 \mid p = 0.25) = \sum_{x=9}^{20} b(x; 20, 0.25) = 0.0409.$$

중요 내용 정리: significance level은 H_0 가 참인데도 기각할 위험을 의미한다.

Probability of Type II Error

The probability of a Type II error is denoted by β .

$$\beta = P(\text{Type II error}) = P(\text{fail to reject } H_0 \mid H_0 \text{ false}).$$

If the true alternative is $p = 0.5$ in the vaccine example,

$$\beta = P(X \leq 8 \mid p = 0.5) = \sum_{x=0}^8 b(x; 20, 0.5) = 0.2517.$$

If the alternative is $p = 0.7$,

$$\beta = P(X \leq 8 \mid p = 0.7) = 0.0051.$$

중요 내용 정리: β 는 특정 alternative value를 정해야 계산할 수 있다.

Role of α , β , and Sample Size

For a fixed sample size, reducing one error probability often increases the other.

If the vaccine critical value changes from 8 to 7:

$$\alpha = P(X \geq 8 \mid p = 0.25) = 0.1018,$$

$$\beta = P(X \leq 7 \mid p = 0.5) = 0.1316.$$

- β decreases.
- α increases.

중요 내용 정리: 표본크기를 늘리면 α 와 β 를 동시에 줄일 수 있다.

Continuous Example: Testing a Mean

Consider testing the average weight of male students.

$$H_0 : \mu = 68, \quad H_1 : \mu \neq 68.$$

Suppose the nonrejection region is

$$67 \leq \bar{x} \leq 69.$$

Then the critical region is

$$\bar{x} < 67 \quad \text{or} \quad \bar{x} > 69.$$

중요 내용 정리: two-tailed test에서는 양쪽 극단값이 모두 H_0 를 의심하게 만든다.

Computing α for the Mean Example

Suppose $\sigma = 3.6$ and $n = 36$. Then

$$\sigma_{\bar{X}} = \frac{3.6}{\sqrt{36}} = 0.6.$$

For $H_0 : \mu = 68$,

$$z_1 = \frac{67 - 68}{0.6} = -1.67, \quad z_2 = \frac{69 - 68}{0.6} = 1.67.$$

Thus,

$$\alpha = P(Z < -1.67) + P(Z > 1.67) = 0.0950.$$

중요 내용 정리: critical region을 정하면 H_0 가 참일 때 그 영역에 들어갈 확률이 α 이다.

Power of a Test

Power of a test: the probability of rejecting H_0 when a specific alternative is true.

$$\text{Power} = 1 - \beta.$$

Example: if $\beta = 0.8661$ for the alternative $\mu = 68.5$, then

$$\text{Power} = 1 - 0.8661 = 0.1339.$$

중요 내용 정리: power는 실제 차이가 있을 때 검정이 그 차이를 잡아낼 능력이다.

One-Tailed and Two-Tailed Tests

One-tailed tests:

$$H_0 : \theta = \theta_0, \quad H_1 : \theta > \theta_0$$

또는

$$H_0 : \theta = \theta_0, \quad H_1 : \theta < \theta_0.$$

Two-tailed test:

$$H_0 : \theta = \theta_0, \quad H_1 : \theta \neq \theta_0.$$

중요 내용 정리: alternative hypothesis의 부등호 방향이 critical region의 위치를 결정한다.

Example 10.1

문제: 어떤 rice cereal 제조업자는 1회 제공량당 평균 saturated fat content가 1.5 grams를 초과하지 않는다고 주장한다. 이 주장을 검정하기 위한 null hypothesis와 alternative hypothesis를 세우고, critical region의 위치를 말하라.

제조업자의 주장은 $\mu > 1.5$ 일 때만 반박된다. 따라서

$$H_0 : \mu = 1.5, \quad H_1 : \mu > 1.5.$$

결론: one-tailed test이며, critical region은 test statistic 분포의 오른쪽 꼬리에 위치한다.

Example 10.2

문제: 한 부동산 중개인은 현재 지어지는 private residences의 60%가 3-bedroom homes라고 주장한다. 큰 표본을 조사하여 3-bedroom 비율을 기록한다. 사용할 hypotheses와 critical region의 위치를 정하라.

관측 비율이 0.6보다 지나치게 크거나 작으면 주장을 의심한다. 따라서

$$H_0 : p = 0.6, \quad H_1 : p \neq 0.6.$$

결론: two-tailed test이므로 critical region은 분포의 양쪽 꼬리에 나뉘어 위치한다.

10.3 The Use of P-Values for Decision Making

10.3 P-Values for Decision Making

Traditional testing often fixes $\alpha = 0.05$ or $\alpha = 0.01$ and makes a reject/fail-to-reject decision.

For a two-tailed standard normal test at $\alpha = 0.05$,

$$z < -1.96 \quad \text{or} \quad z > 1.96$$

is the critical region.

- $z = 1.87$ is not significant at 0.05, but it is close.
- The P-value gives a more informative measure of evidence.

중요 내용 정리: P-value는 단순한 기각 여부보다 표본자료가 H_0 에 얼마나 모순되는지 더 세밀하게 보여준다.

Definition of P-Value

A **P-value** is the lowest level of significance at which the observed value of the test statistic is significant.

For a two-tailed test with observed $z = 1.87$,

$$P = 2P(Z > 1.87) = 2(0.0307) = 0.0614.$$

For $z = 2.73$,

$$P = 2P(Z > 2.73) = 2(0.0032) = 0.0064.$$

중요 내용 정리: P-value가 작을수록 H_0 아래에서 현재 표본결과가 나타나기 어렵다는 뜻이다.

Fixed- α Approach

Fixed probability of Type I error:

1. State H_0 and H_1 .
2. Choose a fixed significance level α .
3. Choose a test statistic and establish the critical region.
4. Reject H_0 if the statistic falls in the critical region.
5. Draw a scientific or engineering conclusion.

중요 내용 정리: fixed- α approach는 Type I error의 최대 허용위험을 먼저 정하고 검정을 진행한다.

P-Value Approach

P-value approach:

1. State H_0 and H_1 .
2. Choose an appropriate test statistic.
3. Compute the P-value from the observed statistic.
4. Interpret the P-value using statistical and scientific context.

중요 내용 정리: P-value는 통계적 판단을 돕는 수치이며, 실제 문제의 의미와 함께 해석해야 한다.

10.4 Single Sample: Tests Concerning a Single Mean

10.4 Tests Concerning a Single Mean

We test hypotheses about a single population mean μ .

Typical two-sided test:

$$H_0 : \mu = \mu_0, \quad H_1 : \mu \neq \mu_0.$$

The test is based on the sampling distribution of $\bar{X}$.

- If σ is known, use the standard normal statistic.
- If σ is unknown and normality is assumed, use the t-statistic.

중요 내용 정리: one-sample mean test는 표본평균이 hypothesized mean에서 얼마나 멀리 떨어졌는지 평가한다.

Variance Known: Z-Test

When σ is known,

$$z = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}.$$

For the two-sided alternative $H_1 : \mu \neq \mu_0$, reject H_0 if

$$z < -z_{\alpha/2} \quad \text{or} \quad z > z_{\alpha/2}.$$

For one-sided alternatives:

$$H_1 : \mu > \mu_0 \Rightarrow z > z_{\alpha},$$

$$H_1 : \mu < \mu_0 \Rightarrow z < -z_{\alpha}.$$

중요 내용 정리: z 는 표본평균이 μ_0 에서 표준오차 몇 개만큼 떨어져 있는지 나타낸다.

Example 10.3

문제: 미국에서 지난 1년 동안 기록된 사망자 100명의 평균 수명이 71.8년이었다. 모집단 표준편차가 8.9년이라고 할 때, 현재 평균 수명이 70년보다 크다고 볼 수 있는가? 유의수준 0.05를 사용하라.

$$H_0 : \mu = 70, \quad H_1 : \mu > 70, \quad \alpha = 0.05.$$

Critical region:

$$z > 1.645.$$

계산:

$$z = \frac{71.8 - 70}{8.9/\sqrt{100}} = 2.02.$$

결론: $2.02 > 1.645$ 이므로 H_0 를 기각한다. 평균 수명은 70년보다 크다는 증거가 있다. P-value는 $P(Z > 2.02) = 0.0217$ 이다.

Example 10.4

문제: 한 스포츠 장비 회사는 새로운 synthetic fishing line의 평균 breaking strength가 8 kg이고 표준편차가 0.5 kg이라고 주장한다. 표본 50개의 평균이 7.8 kg일 때, $\alpha = 0.01$ 에서 평균이 8 kg과 다른지 검정하라.

$$H_0 : \mu = 8, \quad H_1 : \mu \neq 8.$$

Critical region:

$$z < -2.575 \quad \text{or} \quad z > 2.575.$$

계산:

$$z = \frac{7.8 - 8}{0.5/\sqrt{50}} = -2.83.$$

결론: $z = -2.83$ 은 critical region에 있으므로 H_0 를 기각한다. 평균 breaking strength는 8 kg이 아니며, 실제로 더 작다고 볼 수 있다. P-value는 0.0046이다.

Relation to Confidence Intervals

Hypothesis testing and confidence intervals are closely related.

For testing

$$H_0 : \mu = \mu_0, \quad H_1 : \mu \neq \mu_0$$

at level α , compute a $100(1 - \alpha)\%$ confidence interval for μ .

- If μ_0 lies outside the interval, reject H_0 .
- If μ_0 lies inside the interval, fail to reject H_0 .

중요 내용 정리: two-sided test와 confidence interval은 같은 sampling distribution에 기반한 서로 연결된 추론 방법이다.

Variance Unknown: One-Sample t-Test

When σ is unknown and the population is normal, use the t-statistic.

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \quad v = n - 1.$$

For

$$H_0 : \mu = \mu_0, \quad H_1 : \mu \neq \mu_0,$$

reject H_0 if

$$t < -t_{\alpha/2, n-1} \quad \text{or} \quad t > t_{\alpha/2, n-1}.$$

중요 내용 정리: 표본표준편차 s 를 사용하면 추가 불확실성이 생기므로 t-distribution을 사용한다.

Example 10.5

문제: 한 기관은 vacuum cleaner가 연평균 46 kWh를 사용한다고 주장한다. 12가구 표본에서 평균 42 kWh, 표준편차 11.9 kWh가 나왔다. 평균 사용량이 46 kWh보다 작다고 볼 수 있는가?
 $\alpha = 0.05$, 정규성 가정.

$$H_0 : \mu = 46, \quad H_1 : \mu < 46.$$

Critical region:

$$t < -1.796, \quad v = 11.$$

계산:

$$t = \frac{42 - 46}{11.9/\sqrt{12}} = -1.16.$$

결론: -1.16 은 critical region에 있지 않으므로 H_0 를 기각하지 않는다. 평균 사용량이 46 kWh보다 작다는 충분한 증거가 없다. P-value는 약 0.135이다.

Comment on the One-Sample t-Test

The t-test requires that the random sample comes from a normal population.

- For small samples, the normality assumption is important.
- For bell-shaped distributions, the t-test often performs reasonably well.
- When the assumption is doubtful, graphical checks or nonparametric methods may be considered.

중요 내용 정리: t-test는 normality assumption에 기반하지만, 완전한 비정규성에는 비교적 robust하게 작동하는 경우가 많다.

Annotated Computer Output: One-Sample t-Test

Suppose pH meter data are

7.07, 7.00, 7.10, 6.97, 7.00, 7.03, 7.01, 7.01, 6.98, 7.08.

Test

$$H_0 : \mu = 7.0, \quad H_1 : \mu \neq 7.0.$$

Computer output gives

$$\bar{y} = 7.0250, \quad s = 0.04403, \quad \text{s. e.}(\bar{y}) = 0.01392, \quad t = 1.80, \quad P = 0.106.$$

중요 내용 정리: P-value가 0.106이므로 보통의 유의수준 0.05에서는 pH meter가 biased라고 볼 충분한 증거가 없다.

10.5 Two Samples: Tests on Two Means

10.5 Tests on Two Means

Two-sample tests compare two population means.

General hypothesis:

$$H_0 : \mu_1 - \mu_2 = d_0.$$

Alternative hypotheses may be

$$\mu_1 - \mu_2 < d_0, \quad \mu_1 - \mu_2 > d_0, \quad \mu_1 - \mu_2 \neq d_0.$$

중요 내용 정리: two-sample mean test의 핵심은 $\bar{X}_1 - \bar{X}_2$ 의 sampling distribution이다.

Two Means: Variances Known

If σ_1 and σ_2 are known, use

$$z = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}.$$

For $H_1 : \mu_1 - \mu_2 \neq d_0$, reject H_0 if

$$z < -z_{\alpha/2} \quad \text{or} \quad z > z_{\alpha/2}.$$

중요 내용 정리: 두 표본이 독립이면 차이의 분산은 각 표본평균 분산의 합이다.

Two-Sample Pooled t-Test

If variances are unknown but assumed equal, use the pooled variance estimate.

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}.$$

$$t = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{s_p \sqrt{1/n_1 + 1/n_2}}, \quad v = n_1 + n_2 - 2.$$

중요 내용 정리: pooled t-test는 두 모집단의 variance가 같다는 가정 아래 두 sample variance를 합쳐서 사용한다.

Example 10.6

문제: 두 laminated material의 abrasive wear를 비교한다. Material 1은 $n_1 = 12$, $\bar{x}_1 = 85$, $s_1 = 4$ 이고, Material 2는 $n_2 = 10$, $\bar{x}_2 = 81$, $s_2 = 5$ 이다. Material 1의 평균 wear가 Material 2보다 2 units 이상 더 크다고 볼 수 있는가? $\alpha = 0.05$, equal variances 가정.

$$H_0 : \mu_1 - \mu_2 = 2, \quad H_1 : \mu_1 - \mu_2 > 2.$$

$$s_p = \sqrt{\frac{(11)(16) + (9)(25)}{20}} = 4.478.$$

$$t = \frac{(85 - 81) - 2}{4.478\sqrt{1/12 + 1/10}} = 1.04.$$

결론: $t = 1.04 < 1.725$ 이므로 H_0 를 기각하지 않는다. Material 1의 wear가 Material 2보다 2 units 이상 더 크다는 충분한 증거가 없다. P-value는 약 0.16이다.

Unknown and Unequal Variances

If the variances are unknown and not assumed equal, use the approximate t-statistic.

$$t' = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}.$$

$$v = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{(s_1^2/n_1)^2/(n_1 - 1) + (s_2^2/n_2)^2/(n_2 - 1)}.$$

중요 내용 정리: unequal variance case에서는 Satterthwaite approximation으로 degrees of freedom을 추정한다.

Paired Observations

For paired observations, reduce the two-sample problem to a one-sample problem using differences.

$$d_i = x_{1i} - x_{2i}, \quad i = 1, 2, \dots, n.$$

$$t = \frac{\bar{d} - d_0}{s_d / \sqrt{n}}, \quad v = n - 1.$$

- Each unit receives both conditions.
- The difference removes unit-to-unit variation.

중요 내용 정리: paired t-test는 독립표본 비교가 아니라 같은 대상에서 얻은 두 측정값의 차이를 분석한다.

Interaction in a Paired t-Test

Pairing is useful when experimental units are homogeneous.

$$D_i = X_{1i} - X_{2i}, \quad \text{Var}(D_i) = \sigma_1^2 + \sigma_2^2 - 2 \text{Cov}(X_{1i}, X_{2i}).$$

If the covariance is positive, $\text{Var}(D_i)$ is reduced. But if treatment effects vary strongly across units, interaction may inflate the variability of differences.

중요 내용 정리: pairing의 장점은 차이의 분산을 줄이는 것이지만, treatment와 unit 사이의 interaction이 크면 장점이 약해질 수 있다.

Case Study 10.1: Blood Sample Data

문제: deer에게 succinylcholine을 주입한 직후와 30분 후의 androgen level을 비교한다. 15마리 deer에서 paired observations가 주어졌다. $\alpha = 0.05$ 에서 평균 농도가 변했는지 검정하라.

$$H_0 : \mu_D = 0, \quad H_1 : \mu_D \neq 0.$$

주어진 차이값에 대해

$$\bar{d} = 9.848, \quad s_d = 18.474, \quad n = 15.$$

$$t = \frac{9.848 - 0}{18.474/\sqrt{15}} = 2.06.$$

결론: $|t| = 2.06 < 2.145$ 이므로 0.05 수준에서는 기각하지 않는다. 그러나 P-value가 약 0.06이므로 androgen level 차이에 대한 어느 정도의 증거는 있다.

Test Procedures for Means

Situation	Test statistic	Critical region pattern
One mean, σ known	$z = (\bar{x} - \mu_0)/(\sigma/\sqrt{n})$	use z_α or $z_{\alpha/2}$
One mean, σ unknown	$t = (\bar{x} - \mu_0)/(s/\sqrt{n})$	use t with $v = n - 1$
Two means, σ_1, σ_2 known	$z = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}}$	use z critical values
Two means, equal unknown variances	$t = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{s_p \sqrt{1/n_1 + 1/n_2}}$	use $t, v = n_1 + n_2 - 2$
Two means, unequal unknown variances	$t' = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{\sqrt{s_1^2/n_1 + s_2^2/n_2}}$	use approximate t
Paired observations	$t = (d - d_0)/(s_d/\sqrt{n})$	use $t, v = n - 1$

중요 내용 정리: 평균 검정은 상황에 따라 z , pooled t , Welch-type t' , paired t 중 적절한 statistic을 선택해야 한다.

10.6 Choice of Sample Size for Testing Means

10.6 Choice of Sample Size for Testing Means

Before collecting data, the analyst often chooses a sample size to achieve desired power.

For testing

$$H_0 : \mu = \mu_0, \quad H_1 : \mu > \mu_0,$$

with known variance and specific alternative $\mu = \mu_0 + \delta$,

$$n = \frac{(z_\alpha + z_\beta)^2 \sigma^2}{\delta^2}.$$

중요 내용 정리: sample size는 유의수준, 검정력, 표준편차, 탐지하고 싶은 차이의 크기에 의해 결정된다.

Two-Tailed Sample Size Formula

For a two-tailed test on a single mean,

$$n \approx \frac{(z_{\alpha/2} + z_{\beta})^2 \sigma^2}{\delta^2}.$$

For a two-sample test with $n = n_1 = n_2$ and known σ_1, σ_2 ,

One-tailed:

$$n = \frac{(z_{\alpha} + z_{\beta})^2 (\sigma_1^2 + \sigma_2^2)}{\delta^2}.$$

Two-tailed:

$$n \approx \frac{(z_{\alpha/2} + z_{\beta})^2 (\sigma_1^2 + \sigma_2^2)}{\delta^2}.$$

Example 10.7

문제: 남학생 평균 체중에 대해

$$H_0 : \mu = 68, \quad H_1 : \mu > 68$$

를 $\alpha = 0.05$ 에서 검정한다. $\sigma = 5$ 이고, 실제 평균이 69일 때 power가 0.95가 되려면 표본크기는 얼마인가?

Power가 0.95이므로 $\beta = 0.05$ 이다. 따라서

$$z_\alpha = z_\beta = 1.645, \quad \delta = 69 - 68 = 1.$$

$$n = \frac{(1.645 + 1.645)^2(25)}{1^2} = 270.6.$$

결론: 필요한 표본크기는 $n = 271$ 이다.

Example 10.8

문제: 두 catalysts의 reaction yield를 비교한다. Equal variance를 가정하고 two-sample t-test를 수행한다. $\alpha = 0.05$ 인 two-tailed test에서 차이 0.8σ 를 power 0.9로 탐지하려면 각 catalyst당 표본크기는 얼마인가?

$$H_0 : \mu_1 = \mu_2, \quad H_1 : \mu_1 \neq \mu_2.$$
$$\Delta = \frac{|0.8\sigma|}{\sigma} = 0.8, \quad \beta = 0.1.$$

Table A.9를 사용하면

$$n = 34.$$

결론: 각 catalyst에 대해 34개의 관측값이 필요하다.

10.7 Graphical Methods for Comparing Means

10.7 Graphical Methods for Comparing Means

Graphical methods support, but do not replace, formal tests.

For comparing means, side-by-side box-and-whisker plots are useful because they show:

- median and quartiles;
- spread and extremes;
- possible differences in location and variability.

중요 내용 정리: 그래프는 검정통계량의 판단을 보완하며, 차이가 왜 나타났는지 직관적으로 보여준다.

Boxplots for Comparing Groups

Boxplots may reveal whether groups differ in center or variability.

- For plasma ascorbic acid data, boxplots suggest small difference in means and possibly different variabilities.
- For seedling data, boxplots suggest nitrogen increases stem weights and perhaps variability.

A rough visual guide: if the 25th percentile line for one sample exceeds the median line for the other sample, there may be strong evidence of a difference in means.

중요 내용 정리: boxplot은 formal test 전후에 자료의 구조와 가정 위반 가능성을 확인하는데 도움이 된다.

Annotated Computer Output: Two-Sample t-Test

For seedling data with nitrogen and no nitrogen, SAS output gives:

$$\bar{x}_{\text{No nitrogen}} = 0.3990, \quad s = 0.0728,$$

$$\bar{x}_{\text{Nitrogen}} = 0.5650, \quad s = 0.1867.$$

The unequal variance t-test gives

$$t = 2.62, \quad P = 0.0229.$$

The F-test for equality of variances gives

$$F = 6.58, \quad P = 0.0098.$$

중요 내용 정리: 평균 차이뿐 아니라 variance 차이도 함께 확인해야 한다.

10.8 One Sample: Test on a Single Proportion

10.8 Test on a Single Proportion

We test a binomial parameter p .

$$H_0 : p = p_0.$$

Possible alternatives:

$$p < p_0, \quad p > p_0, \quad p \neq p_0.$$

For small samples, use exact binomial probabilities and P-values.

중요 내용 정리: single proportion test는 성공횟수 X 또는 표본비율 $\hat{p} = X/n$ 을 이용한다.

Small-Sample Proportion Test

Use the binomial random variable X .

For $H_1 : p < p_0$:

$$P\text{-value} = P(X \leq x \mid p = p_0).$$

For $H_1 : p > p_0$:

$$P\text{-value} = P(X \geq x \mid p = p_0).$$

For $H_1 : p \neq p_0$:

$$P\text{-value} = 2P(X \leq x \mid p = p_0) \quad \text{if } x < np_0,$$

$$P\text{-value} = 2P(X \geq x \mid p = p_0) \quad \text{if } x > np_0.$$

Example 10.9

문제: 한 builder는 Richmond의 새 주택 중 70%에 heat pump가 설치된다고 주장한다. 새 주택 15채 중 8채에 heat pump가 있었다. $\alpha = 0.10$ 에서 이 주장에 동의할 수 있는가?

$$H_0 : p = 0.7, \quad H_1 : p \neq 0.7.$$

여기서 $x = 8$, $n = 15$, $np_0 = 10.5$ 이다.

$$P = 2P(X \leq 8 \mid p = 0.7) = 0.2622.$$

결론: $0.2622 > 0.10$ 이므로 H_0 를 기각하지 않는다. builder의 주장을 의심할 충분한 이유가 없다.

Large-Sample Proportion Test

For large n , use the normal approximation.

$$z = \frac{x - np_0}{\sqrt{np_0q_0}} = \frac{\hat{p} - p_0}{\sqrt{p_0q_0/n}}, \quad q_0 = 1 - p_0.$$

Critical regions:

- $H_1 : p < p_0 : z < -z_\alpha.$
- $H_1 : p > p_0 : z > z_\alpha.$
- $H_1 : p \neq p_0 : z < -z_{\alpha/2} \text{ or } z > z_{\alpha/2}.$

중요 내용 정리: large-sample proportion test는 binomial을 normal approximation으로 바꾸어 계산한다.

Example 10.10

문제: 기존 nervous tension 완화 약은 60% 효과가 있다고 알려져 있다. 새로운 약을 100명에게 투여했더니 70명이 relief를 얻었다. $\alpha = 0.05$ 에서 새 약이 더 우수하다고 할 수 있는가?

$$H_0 : p = 0.6, \quad H_1 : p > 0.6.$$

$$\hat{p} = 0.7, \quad z = \frac{0.7 - 0.6}{\sqrt{(0.6)(0.4)/100}} = 2.04.$$

결론: $z = 2.04 > 1.645$ 이므로 H_0 를 기각한다. 새 약이 더 우수하다는 증거가 있다. P-value는 $P(Z > 2.04) < 0.0207$ 이다.

10.9 Two Samples: Tests on Two Proportions

10.9 Tests on Two Proportions

We test whether two binomial parameters are equal.

$$H_0 : p_1 = p_2 \iff H_0 : p_1 - p_2 = 0.$$

Alternatives:

$$p_1 < p_2, \quad p_1 > p_2, \quad p_1 \neq p_2.$$

중요 내용 정리: two-proportion test는 두 독립 표본의 성공비율 차이가 우연히 나타난 정도인지 판단한다.

Pooled Estimate for Two Proportions

Under $H_0 : p_1 = p_2$, the common proportion is estimated by pooling.

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}, \quad \hat{q} = 1 - \hat{p}.$$
$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}\hat{q}(1/n_1 + 1/n_2)}}.$$

- Use right-tail critical region for $H_1 : p_1 > p_2$.
- Use left-tail critical region for $H_1 : p_1 < p_2$.
- Use both tails for $H_1 : p_1 \neq p_2$.

Example 10.11

문제: 화학공장 건설안에 대해 town voters 200명 중 120명, county voters 500명 중 240명이 찬성했다. town voters의 찬성비율이 county voters보다 높다고 할 수 있는가? $\alpha = 0.05$.

$$H_0 : p_1 = p_2, \quad H_1 : p_1 > p_2.$$

$$\hat{p}_1 = \frac{120}{200} = 0.60, \quad \hat{p}_2 = \frac{240}{500} = 0.48.$$

$$\hat{p} = \frac{120 + 240}{200 + 500} = 0.51.$$

$$z = \frac{0.60 - 0.48}{\sqrt{(0.51)(0.49)(1/200 + 1/500)}} = 2.9.$$

결론: $z = 2.9 > 1.645$ 이므로 H_0 를 기각한다. town voters의 찬성비율이 더 높다는 증거가 있다. P-value는 0.0019이다.

10.10 One- and Two-Sample Tests Concerning Variances

10.10 Tests Concerning Variances

Variance tests are used when variability itself is important.

- Process specifications may require small variability.
- Comparative experiments may require checking reproducibility.
- Equality of variances may be checked before a pooled t-test.

중요 내용 정리: variance test는 평균이 아니라 흩어짐의 크기에 대한 검정이다.

Single Variance: Chi-Squared Test

Assume the population is normal. To test

$$H_0 : \sigma^2 = \sigma_0^2,$$

use

$$\chi^2 = \frac{(n-1)s^2}{\sigma_0^2}, \quad v = n - 1.$$

Critical regions:

- $H_1 : \sigma^2 > \sigma_0^2$: $\chi^2 > \chi_\alpha^2$.
- $H_1 : \sigma^2 < \sigma_0^2$: $\chi^2 < \chi_{1-\alpha}^2$.
- $H_1 : \sigma^2 \neq \sigma_0^2$: two tails.

중요 내용 정리: single variance test는 normality assumption에 매우 민감하다.

Robustness of the Chi-Squared Variance Test

The chi-squared test for a single variance is not robust to nonnormality.

If the underlying distribution is not normal, a significant result may be caused by violation of normality rather than a true variance difference.

- Normal probability plots can be useful.
- Goodness-of-fit procedures can be used to check assumptions.

중요 내용 정리: variance에 대한 χ^2 test는 normality check 없이 기계적으로 사용하면 위험하다.

Example 10.12

문제: 한 car battery 제조업자는 battery life가 정규분포를 따르며 표준편차가 0.9년이라고 주장한다. 10개 표본의 표준편차가 1.2년이었다. $\alpha = 0.05$ 에서 $\sigma > 0.9$ 라고 볼 수 있는가?

$$H_0 : \sigma^2 = 0.81, \quad H_1 : \sigma^2 > 0.81.$$

Critical region:

$$\chi^2 > 16.919, \quad v = 9.$$

계산:

$$\chi^2 = \frac{(9)(1.44)}{0.81} = 16.0.$$

결론: $16.0 < 16.919$ 이므로 0.05 수준에서는 기각하지 않는다. 하지만 P-value가 약 0.07이므로 $\sigma > 0.9$ 에 대한 어느 정도의 증거는 있다.

Two Variances: F-Test

For two normal populations, test

$$H_0 : \sigma_1^2 = \sigma_2^2.$$

Use

$$f = \frac{s_1^2}{s_2^2}, \quad v_1 = n_1 - 1, \quad v_2 = n_2 - 1.$$

Critical regions:

- $H_1 : \sigma_1^2 > \sigma_2^2: f > f_\alpha(v_1, v_2).$
- $H_1 : \sigma_1^2 < \sigma_2^2: f < f_{1-\alpha}(v_1, v_2).$
- $H_1 : \sigma_1^2 \neq \sigma_2^2: \text{two tails}.$

Example 10.13

문제: Example 10.6에서 두 material의 population variance가 같다고 가정했다. 이 가정이 타당한지 $\alpha = 0.10$ 에서 검정하라.

$$H_0 : \sigma_1^2 = \sigma_2^2, \quad H_1 : \sigma_1^2 \neq \sigma_2^2.$$

$$s_1^2 = 16, \quad s_2^2 = 25, \quad f = \frac{16}{25} = 0.64.$$

Critical region:

$$f < 0.34 \quad \text{or} \quad f > 3.11.$$

결론: 0.64는 critical region에 있지 않으므로 H_0 를 기각하지 않는다. 두 variances가 다르다는 충분한 증거가 없다.

10.11 Goodness-of-Fit Test

10.11 Goodness-of-Fit Test

A goodness-of-fit test determines whether a population has a specified theoretical distribution.

$$\chi^2 = \sum_{i=1}^k \frac{(o_i - e_i)^2}{e_i}, \quad v = k - 1.$$

- o_i : observed frequency in cell i .
- e_i : expected frequency in cell i .
- Large χ^2 indicates poor fit.

중요 내용 정리: observed frequency와 expected frequency의 차이가 클수록 가정한 분포와 맞지 않는다.

Goodness-of-Fit Example: Die Tosses

An honest die is tossed 120 times. Expected frequency for each face is 20.

Face	1	2	3	4	5	6
Observed	20	22	17	18	19	24
Expected	20	20	20	20	20	20

$$\chi^2 = \sum_{i=1}^6 \frac{(o_i - e_i)^2}{e_i} = 1.7.$$

For $v = 5$, $\chi_{0.05}^2 = 11.070$.

결론: $1.7 < 11.070$ 이므로 H_0 를 기각하지 않는다. 주사위가 균형잡혀 있지 않다고 볼 충분한 증거가 없다.

Expected Frequencies and Cell Combining

The goodness-of-fit test should not be used unless expected frequencies are sufficiently large.

Rule of thumb: each expected frequency should be at least 5.

If an expected frequency is too small:

- combine adjacent cells;
- reduce the number of degrees of freedom accordingly.

중요 내용 정리: expected frequency가 너무 작으면 χ^2 approximation의 신뢰성이 떨어진다.

Normal Fit Example: Battery Lives

For battery lives, suppose the hypothesized distribution is normal with

$$\mu = 3.5, \quad \sigma = 0.7.$$

Expected frequencies are obtained from normal curve areas between class boundaries.

For the class 2.95 to 3.45,

$$z_1 = \frac{2.95 - 3.5}{0.7} = -0.79, \quad z_2 = \frac{3.45 - 3.5}{0.7} = -0.07.$$

$$P(-0.79 < Z < -0.07) = 0.4721 - 0.2148 = 0.2573.$$

$$e_4 = (0.2573)(40) = 10.3.$$

Normal Fit Example: Decision

After combining adjacent classes with small expected frequencies, the computed statistic is

$$\chi^2 = 3.05.$$

The degrees of freedom are

$$v = 3.$$

For $\alpha = 0.05$,

$$\chi_{0.05}^2 = 7.815.$$

결론: $3.05 < 7.815$ 이므로 normal distribution with $\mu = 3.5$ and $\sigma = 0.7$ provides an adequate fit for the battery-life data.

Geary's Test for Normality

Geary's test is another method for testing normality.

$$U = \frac{\sqrt{\pi/2} \sum_{i=1}^n |X_i - \bar{X}|/n}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2/n}}.$$

For large samples,

$$Z = \frac{U - 1}{0.2661/\sqrt{n}}.$$

Values of U far from 1 suggest departure from normality.

중요 내용 정리: normality 검정은 이후의 t-test, F-test, χ^2 variance test의 타당성과 연결된다.

10.12 Test for Independence

10.12 Test for Independence

The chi-squared procedure can test whether two categorical variables are independent.

For an $r \times c$ contingency table,

$$\chi^2 = \sum \frac{(o_i - e_i)^2}{e_i}, \quad v = (r - 1)(c - 1).$$

Expected frequency for a cell:

$$e = \frac{(\text{row total})(\text{column total})}{\text{grand total}}.$$

중요 내용 정리: independence test는 두 categorical variables가 서로 관련이 있는지 판단한다.

Contingency Table Example

Tax reform opinion by income level:

	Low	Medium	High	Total
For	182	213	203	598
Against	154	138	110	402
Total	336	351	313	1000

Expected frequency for Low and For:

$$e = \frac{(336)(598)}{1000} = 200.9.$$

중요 내용 정리: expected frequency는 independence가 맞다고 가정했을 때 각 cell에 기대되는 빈도이다.

Independence Test: Decision

For the tax reform table,

$$\chi^2 = 7.85, \quad v = (2 - 1)(3 - 1) = 2.$$

At $\alpha = 0.05$,

$$\chi_{0.05}^2 = 5.991.$$

Since

$$7.85 > 5.991,$$

reject the null hypothesis of independence.

결론: tax reform에 대한 opinion과 income level은 independent라고 보기 어렵다. P-value는 약 0.02이다.

Yates Correction and Small Expected Frequencies

For a 2×2 table with small expected frequencies, Yates' correction may be used.

$$\chi^2(\text{corrected}) = \sum_i \frac{(|o_i - e_i| - 0.5)^2}{e_i}.$$

Guidelines:

- If expected frequencies are large, corrected and uncorrected results are similar.
- If expected frequencies are between 5 and 10, Yates' correction may be used.
- If expected frequencies are less than 5, Fisher-Irwin exact test is preferred.

10.13 Test for Homogeneity

10.13 Test for Homogeneity

A test for homogeneity applies when row or column totals are fixed in advance.

Question: Are several populations homogeneous with respect to categorical response proportions?

The same chi-squared statistic is used:

$$\chi^2 = \sum \frac{(o_i - e_i)^2}{e_i}, \quad v = (r - 1)(c - 1).$$

중요 내용 정리: homogeneity test는 여러 집단에서 범주별 비율이 같은지 비교한다.

Example 10.14

문제: North Carolina voters를 Democrats 200명, Republicans 150명, Independents 150명으로 미리 정해 뽑고 abortion law에 대한 의견을 조사했다. 세 정치집단의 의견분포가 같은지 $\alpha = 0.05$ 에서 검정하라.

H_0 : 각 opinion category의 proportions가 정치집단별로 같다.

H_1 : 적어도 하나의 opinion category에서 proportions가 다르다.

Degrees of freedom:

$$v = (3 - 1)(3 - 1) = 4.$$

Critical region:

$$\chi^2 > 9.488.$$

계산 결과:

$$\chi^2 = 1.53.$$

결론: $1.53 < 9.488$ 이므로 H_0 를 기각하지 않는다. 정치집단별 의견분포가 다르다고 볼 충분한 증거가 없다.

Testing Several Proportions

Testing homogeneity also applies to testing equality of several binomial parameters.

$$H_0 : p_1 = p_2 = \cdots = p_k.$$

H_1 : not all proportions are equal.

Data are arranged in a $2 \times k$ contingency table:

Sample	1	2	$\cdots$	k
Successes	x_1	x_2	$\cdots$	x_k
Failures	$n_1 - x_1$	$n_2 - x_2$	$\cdots$	$n_k - x_k$

$$v = k - 1.$$

Example 10.15

문제: Day, Evening, Night shifts에서 defective proportion이 같은지 조사한다. 유의수준 0.025에서 검정하라.

Shift	Day	Evening	Night
Defectives	45	55	70
Nondefectives	905	890	870

$$H_0 : p_1 = p_2 = p_3, \quad H_1 : \text{not all equal.}$$

$$v = 2, \quad \chi^2_{0.025} = 7.378.$$

계산 결과:

$$\chi^2 = 6.29, \quad P \approx 0.04.$$

결론: $\alpha = 0.025$ 에서는 H_0 를 기각하지 않는다. 그러나 P-value가 약 0.04이므로 shifts별 defective proportion이 같다고 단정하기는 위험하다.

10.14 Two-Sample Case Study

10.14 Two-Sample Case Study

Two alloys, A and B, are compared in terms of breaking strength. Alloy B is more expensive, so adoption requires evidence that it is stronger.

Concerns:

- average strength;
- reproducibility or variability;
- normality assumptions for t- and F-tests.

Sample summaries:

$$\bar{y}_A = 83.55, \quad s_A = 3.663,$$

$$\bar{y}_B = 79.70, \quad s_B = 3.097.$$

중요 내용 정리: 실제 분석에서는 평균 차이뿐 아니라 **variability**와 **normality**도 함께 검토해야 한다.

Case Study: Formal Test Results

For the alloy data, the F-test gives

$$F = 1.40, \quad P = 0.4709.$$

Thus, there is no significant evidence of unequal variances.

Pooled two-sample t-test for

$$H_0 : \mu_A = \mu_B, \quad H_1 : \mu_A > \mu_B$$

gives

$$t = 3.59, \quad P = 0.0009.$$

결론: Alloy B has significantly smaller deflection, suggesting stronger performance. Adoption of alloy B may be statistically supported.

Statistical Significance and Practical Significance

A statistically significant result does not automatically imply practical importance.

In the alloy case,

$$\bar{y}_A - \bar{y}_B = 0.00385 \text{ inch.}$$

This difference is statistically significant, but the engineer must decide whether it justifies the higher cost of alloy B.

중요 내용 정리: statistical significance는 “우연으로 보기 어려운 차이”를 말하며, engineering or scientific significance는 실제 의사결정에서 의미 있는 차이인지를 말한다.

10.15 Potential Misconceptions and Hazards

10.15 Potential Misconceptions and Hazards

A common misuse is concluding that H_0 is true when it is not rejected.

Failing to reject H_0 means insufficient evidence against H_0 . It does not prove H_0 .

Example: if two gauges are compared and H_0 says they are equivalent, failing to reject H_0 does not prove equivalence.

중요 내용 정리: 검정에서 “fail to reject”는 “동등함을 증명”한 것이 아니라 “차이를 보일 증거가 부족”하다는 뜻이다.

Hazard: Replacing σ by s

Using

$$z = \frac{\bar{x} - \mu}{s/\sqrt{n}}$$

can be risky when $n < 30$.

- If $n \geq 30$ and the distribution is close to normal, $s \approx \sigma$ may be reasonable.
- For small samples, use of s requires care and often the t-distribution.
- t-tests are relatively robust, but graphical checks are still useful.

중요 내용 정리: small sample에서 σ 를 모를 때 s 를 넣고 곧바로 z-test를 쓰는 것은 위험하다.

Relationship to Later Chapters

Hypothesis testing is central to many later statistical methods.

Concepts that will continue to appear:

- test statistics;
- P-values;
- power and sample size;
- model checking and diagnostic procedures.

중요 내용 정리: regression, analysis of variance, and model diagnostics all rely heavily on the hypothesis testing framework developed in this chapter.

Chapter 10 Exercise Themes

Practice Problems: Error Probabilities and P-Values

Exercises 10.1–10.18 focus on foundational hypothesis-testing concepts.

- Type I and Type II errors in real contexts.
- Computing α and β using binomial and normal approximation.
- Understanding power and operating characteristic curves.

중요 내용 정리: 초기 연습문제의 목적은 검정절차의 논리, 오류확률, 표본크기의 역할을 계산으로 확인하는 것이다.

Practice Problems: Means and Proportions

Exercises 10.19–10.66 focus on one- and two-sample tests for means and proportions.

- One-sample z- and t-tests for means.
- Two-sample pooled and unpooled t-tests.
- Paired t-tests.
- One- and two-sample tests for proportions.
- Sample size for desired power.

중요 내용 정리: 평균 검정에서는 variance known/unknown, independent/paired, equal/unequal variance 여부를 먼저 판단해야 한다.

Practice Problems: Variances and Categorical Data

Exercises 10.67–10.111 focus on tests for variances, goodness-of-fit, independence, homogeneity, and review applications.

- χ^2 tests for a single variance.
- F-tests for two variances.
- Goodness-of-fit tests for theoretical distributions.
- Tests for independence and homogeneity in contingency tables.
- Integrated review problems combining choice of method and interpretation.

중요 내용 정리: categorical data analysis에서는 observed frequency와 expected frequency의 차이가 핵심이다.